

Titolo italiano: Confronto di tecniche di steganografia tramite modelli generativi
Titolo inglese: Comparing of steganography techniques using generative models
Candidato: Matteo Diciotti
Relatore: Prof. Daniele Baracchi
Correlatrice: Dott.ssa Giulia Bertazzini
Correlatore: Prof. Daniele Castellana
Anno accademico: 2025-2026

Riassunto

La steganografia occulta l'esistenza di una comunicazione dentro oggetti multimediali innocui. Mentre la crittografia produce traffico cifrato identificabile, la steganografia mira all'indistinguibilità statistica del flusso comunicativo. Un paradigma recente è la *Steganography without Embedding* (SwE), in cui il messaggio segreto guida la generazione di un nuovo artefatto invece di essere nascosto in un contenuto preesistente. L'esempio principale è Meteor, un algoritmo a chiave simmetrica che sfrutta un Large Language Model per pilotare i token testuali via arithmetic coding, producendo stego-text indistinguibili dall'output del modello.

Questa tesi indaga se un approccio analogo a Meteor sia applicabile al dominio visivo. L'obiettivo non è un sistema pronto all'uso, ma esplorare le condizioni in cui un modello generativo visuale può fungere da sampler steganografico, individuando i fattori che lo rendono possibile o lo limitano.

Il percorso sperimentale parte da VQ-GAN, che abbina un codebook discreto di token visivi a un Transformer autoregressivo (analogia con i modelli linguistici). L'implementazione mostra che encoder e decoder non sono funzioni inverse: circa il 19% dei token non sopravvive al round-trip attraverso i pixel, impedendo il recupero del messaggio. Il fine-tuning dell'encoder, con decoder e codebook congelati, riduce ma non elimina l'errore, a causa del condizionamento laterale tra posizioni adiacenti. Un esperimento su canale lossless conferma l'equivalenza algoritmica (recupero completo), mostrando che l'ostacolo è nel canale, non nell'algoritmo.

Con Open-MAGVIT2, tokenizer basato sulla *Lookup-Free Quantization* (LFQ), emerge un secondo problema. La LFQ è matematicamente invertibile, ma il canale PNG quantizza i pixel a 8 bit e altera circa il 16.8% dei token (1.1% per bit). Poiché ogni token dipende da tutti i precedenti, un singolo errore si propaga a cascata corrompendo le predizioni successive. Il bit error rate end-to-end raggiunge circa il 65%, aggravato dal disallineamento del flusso binario dovuto al bitrate variabile dell'arithmetic coding.

Per aggirare la propagazione si adotta una strategia alternativa: i bit del messaggio sono scritti direttamente nei piani di bit dei codici latenti di un'immagine esistente (Quantization Index Modulation, QIM), eliminando la dipendenza dal campionamento sequenziale. Con codici Reed-Solomon il recupero è completo, con capacità di 30–50 byte per immagini 256×256 pixel. Questa soluzione è però un watermark robusto ma statisticamente rilevabile, non steganografia indistinguibile: la modulazione dei codici introduce perturbazioni rilevabili, specie alterando più della metà dei 18 piani di bit.

Il risultato centrale è un trade-off tra indistinguibilità statistica (campionamento autoregressivo) e robustezza al canale (modulazione diretta dei codici): le due proprietà sono mutuamente esclusive per questo tipo di sistemi. La trasposizione di SwE al dominio visivo è concettualmente possibile, come mostra l'esperimento su canale lossless, ma è vincolata dall'assenza di un canale privo di rumore tra token e pixel. Proprietà di cui il dominio testuale gode intrinsecamente e su cui si fonda il successo di Meteor.