



UNIVERSITÀ
DEGLI STUDI
FIRENZE

Scuola di Scienze Matematiche, Fisiche e Naturali
Corso di Laurea in Informatica

Tesi di Laurea

STEGANOGRAFIA GENERATIVA SU
IMMAGINI:
ADATTAMENTO DEL PROTOCOLLO METEOR
TRAMITE L'ARCHITETTURA VQ-GAN

GENERATIVE IMAGE STEGANOGRAPHY:
ADAPTING THE METEOR PROTOCOL TO THE
VQ-GAN ARCHITECTURE

MATTEO DICIOTTI

Relatore: Prof. *Daniele Baracchi*

Correlatrice: PhD *Giulia Bertazzini*

Correlatore: Prof. *Daniele Castellana*

Anno Accademico 2024-2025

Matteo Diciotti: *Steganografia generativa su immagini:*
adattamento del protocollo Meteor tramite l'architettura VQ-GAN, Corso di
Laurea in Informatica, © Anno Accademico 2024-2025

INDICE

Elenco delle figure	3
1 Introduzione	7
2 Stato dell'arte	11
2.1 Meteor: un framework di steganografia generativa per il testo	11
Bibliografia	17

ELENCO DELLE FIGURE

Figura 1	Rappresentazione schematica di una comunicazione tra Alice (A) e Bob (B) in presenza di un osservatore esterno, Eve (E), e di un sistema di filtraggio dei contenuti, come un firewall governativo, progettato per monitorare e bloccare il traffico sospetto.	14
----------	--	----

"Questo è bello!"
"Eh, nella sua semplicità.."
"Questo è iper-realista."
"E se me lo concedi monocromatico."
"L'artista è Meteor."
"Meteor, già sentito!"
— Aldo, Giovanni e Giacomo

INTRODUZIONE

L'esigenza intrinseca e crescente di garantire comunicazioni che siano contemporaneamente riservate, autentiche e integre rappresenta un pilastro fondamentale su cui si erge l'architettura stessa del mondo digitale contemporaneo. La sicurezza delle informazioni, in passato, è stata prevalentemente affidata a robuste tecniche crittografiche e a protocolli standard ben consolidati, quali il Transport Layer Security (TLS) e il suo predecessore Secure Sockets Layer (SSL). Questi sistemi sono stati meticolosamente progettati per rendere il contenuto effettivo dei messaggi inaccessibile a qualsiasi entità esterna non in possesso delle chiavi di decifratura appropriate; nel contesto di TLS, ciò si traduce tipicamente nell'esclusione di chiunque non partecipi al processo di negoziazione della connessione (l'handshake).

Tuttavia, l'escalation senza precedenti delle misure di sorveglianza di massa su scala globale e la proliferazione di meccanismi di censura sempre più capillari e sofisticati hanno messo a nudo una vulnerabilità critica, intrinseca e finora difficile da eradicare alla crittografia moderna: la sua stessa visibilità. Sebbene la crittografia riesca efficacemente a mantenere segreto il contenuto dei dati trasmessi, l'elevata entropia e le caratteristiche distintive del traffico cifrato lo rendono facilmente identificabile e distinguibile dalle comunicazioni in chiaro. Questo stato di cose consente a regimi autoritari, a entità statali o a sofisticati sistemi di filtraggio di rete (come i firewall avanzati) di individuare, bloccare o degradare selettivamente le comunicazioni protette, compromettendo così l'effettivo scambio di informazioni sensibili in contesti operativi ostili o sorvegliati.

Di fronte a tali sfide, specialmente in scenari caratterizzati da censura estrema o da ambienti di comunicazione altamente avversari, emerge in modo prepotente la necessità di esplorare e impiegare metodologie steganografiche. La steganografia, come disciplina, si dedica all'arte e alla scienza dell'occultamento di informazioni segrete all'interno di oggetti

di copertura (cover objects) che, a un'osservazione superficiale, appaiono del tutto innocui e non sospetti. Questi oggetti di copertura possono assumere svariate forme, tra cui testi, immagini, file audio o video. A differenza della crittografia, il cui successo e la cui sicurezza dipendono in larga misura dalla complessità matematica o computazionale necessaria per decifrare il messaggio cifrato, la sicurezza in ambito steganografico poggia su un principio radicalmente diverso: l'indistinguibilità statistica. L'obiettivo primario è fare in modo che un osservatore esterno non sia minimamente in grado di discriminare tra un oggetto che contiene un messaggio segreto (denominato stego-object) e un oggetto analogo che ne è privo.

Le metodologie steganografiche classiche, quali ad esempio la manipolazione dei bit meno significativi (Least Significant Bit - LSB) nelle immagini digitali, si sono progressivamente rivelate vulnerabili agli attacchi di crittoanalisi statistica sempre più avanzati e raffinati. Per superare queste limitazioni intrinseche e garantire un livello di sicurezza che sia non solo robusto ma anche dimostrabile, la ricerca più recente ha abbracciato un vero e proprio cambio di paradigma. Questo nuovo orientamento si concentra sull'utilizzo strategico di modelli generativi, in particolare quelli basati su reti neurali profonde.

In questo fertile contesto di ricerca si inserisce **Meteor**, un innovativo algoritmo di steganografia a chiave simmetrica. Meteor sfrutta le potenti capacità computazionali e generative dei modelli di linguaggio di grandi dimensioni (Large Language Models - LLM), originariamente derivati da architetture come GPT-2, per creare canali di comunicazione occulti e resilienti. A differenza delle tecniche steganografiche tradizionali che modificano un contenuto esistente, Meteor interviene e guida il processo di generazione stessa del contenuto. Esso utilizza la distribuzione di probabilità intrinseca del modello generativo per "pilotare" il campionamento dei token successivi in base al messaggio segreto opportunamente cifrato. Questo approccio garantisce che lo stego-object risultante sia statisticamente coerente e indistinguibile dall'output naturale del modello, rendendo la presenza del messaggio nascosto estremamente difficile, se non impossibile, da rilevare attraverso analisi statistiche convenzionali.

L'ambizioso obiettivo della presente tesi triennale è estendere il principio fondamentale di sicurezza steganografica ideato da Meteor, originariamente applicato al dominio testuale, all'ambito delle immagini digitali ad alta risoluzione. Per conseguire questo scopo, viene sfruttata l'architettura **VQ-GAN** (Vector Quantized Generative Adversarial Network). La scelta strategica di questa specifica architettura deriva dalla

sua intrinseca capacità di modellare immagini estremamente complesse attraverso la creazione e l'utilizzo di un vocabolario discreto di "token visivi", memorizzati in un codebook. Questa rappresentazione discreta apre le porte all'applicazione di un modello Transformer autoregressivo, ampiamente utilizzato nella generazione sequenziale, per guidare il processo di sintesi dell'immagine. Il lavoro svolto mira dunque a dimostrare con rigore e sperimentazione come sia possibile incorporare messaggi cifrati direttamente durante la fase di generazione dell'immagine da parte dell'architettura VQ-GAN. L'obiettivo finale è ottenere immagini non solo visivamente simili a quelle generate dallo stesso modello, ma anche intrinsecamente robuste contro tentativi sofisticati di rilevamento steganografico.

Le implicazioni pratiche e teoriche di questo approccio sono potenzialmente rivoluzionarie per lo sviluppo di strumenti di comunicazione *copyright-resistant*. La capacità di abilitare lo scambio sicuro e nascosto di informazioni all'interno di immagini di alta qualità offre un livello inedito di protezione per la privacy degli utenti e per la libertà di espressione in contesti digitali sempre più soggetti a sorveglianza e controllo.

Il presente elaborato è stato organizzato con cura per condurre il lettore attraverso un percorso logico e approfondito, dalla teoria alla pratica:

- Il **Capitolo 2** fornisce un'analisi completa e dettagliata del background teorico indispensabile, approfondendo lo stato dell'arte delle tecniche steganografiche esistenti e i principi fondamentali di funzionamento dei modelli generativi più avanzati, con un'enfasi particolare sulle architetture GAN (Generative Adversarial Networks) e Transformer.
- Il **Capitolo 3** presenta le definizioni formali e le specifiche tecniche del sistema proposto, illustrando in dettaglio l'architettura implementata e le modifiche apportate al meccanismo di campionamento dei token visivi per consentire l'embedding del messaggio segreto cifrato direttamente nel flusso generativo. Vengono inoltre discussi i limiti teorici e pratici del lavoro svolto, evidenziando le sfide affrontate e le soluzioni adottate per superarle.
- Il **Capitolo 4** presenta l'idea alla base del lavoro di tesi, l'architettura completa del sistema implementato e i limiti teorici e pratici del lavoro svolto. Vengono illustrate in dettaglio le modifiche apportate al meccanismo di campionamento dei token visivi per consentire

l'embedding del messaggio segreto cifrato direttamente nel flusso generativo.

- Il **Capitolo 5** espone in modo esaustivo i risultati delle sperimentazioni condotte. Vengono valutate sia la qualità visiva delle immagini generate, attraverso l'utilizzo di metriche consolidate come la Fréchet Inception Distance (FID), sia la capacità steganografica del sistema, analizzando il payload trasferibile e la robustezza contro attacchi di rilevamento.
- Infine, il **Capitolo 6** trae le conclusioni finali del lavoro svolto, riassumendo i contributi principali della ricerca e delineando una serie di possibili sviluppi futuri, mirati al miglioramento incrementale dell'efficienza, della robustezza e della sicurezza complessiva del sistema proposto.

STATO DELL'ARTE

2.1 METEOR: UN FRAMEWORK DI STEGANOGRAFIA GENERATIVA PER IL TESTO

La necessità di una solida comprensione teorica, indispensabile per contestualizzare appieno il presente lavoro di ricerca, si articola attraverso una costellazione di concetti interdipendenti che convergono armoniosamente in un'unica opera fondamentale: il lavoro di [KAP+21], comunemente noto come *Meteor*. Questa pionieristica indagine, che va oltre una mera disamina della steganografia classica e di quella generativa, introduce primariamente un approccio metodologico e, in secondo luogo, un framework robusto ed efficiente deputato alla *generazione di messaggi testuali contenenti informazioni celate*. La peculiarità di queste informazioni risiede nella loro intrinseca invisibilità non solo all'occhio umano, ma anche, e soprattutto, alle più sofisticate tecniche di steganalisi. La ragione di tale elusività è profonda: il testo generato da *Meteor* non manifesta alcuna deviazione statistica significativa rispetto a un testo prodotto autonomamente dal medesimo modello linguistico di base. Come verrà dettagliato in seguito, *Meteor* si avvale di un modello linguistico che ha raggiunto una notevole notorietà, estendendosi ben oltre gli ambiti accademici tradizionali, potremmo dire il primo del suo genere a varcare le soglie del dibattito pubblico, sebbene gran parte della sua fama derivi dall'influenza esercitata sui suoi successori. Nello specifico, *Meteor* impiega il modello **GPT-2**; tuttavia, la sua architettura è stata concepita con una notevole flessibilità, risultando agnostica rispetto al modello linguistico sottostante. Questo framework rappresenta, pertanto, un pilastro fondamentale per la presente ricerca, configurandosi non solo come un esempio paradigmatico di metodi steganografici capaci di eludere gli attuali algoritmi di steganalisi – la sfida predominante nel campo della steganografia moderna – ma anche come un catalizzatore per nuove direzioni di ricerca.

Per una comprensione ancora più profonda, è opportuno fare un

passo indietro ed esaminare il contesto socio-tecnologico in cui *Meteor* è maturato e le problematiche specifiche che si proponeva di risolvere. Successivamente, analizzeremo le ragioni per cui l'architettura VQ-GAN è stata presa in considerazione come possibile influenza per questo framework, pur tenendo presente che, come si vedrà, non si tratta né dell'unica né dell'architettura intrinsecamente più efficace applicabile in questo ambito.

L'essenza di *Meteor* risiede nell'idea innovativa di utilizzare un modello generativo per la creazione di contenuti steganografici, impiegando le sue capacità per produrre un'approssimazione sufficientemente accurata del linguaggio naturale. In termini pratici, il modello agisce come un sofisticato dizionario: data una sequenza di contesto iniziale, è in grado di fornire una distribuzione di probabilità dettagliata per tutti i possibili *token* linguistici successivi. La scelta del *token* da inserire nella sequenza viene quindi effettuata sulla base di un ordinamento predefinito. Questa metodologia costituisce il nucleo operativo dei moderni modelli generativi di linguaggio, inclusi gli LLM, e può essere abilmente manipolata per generare un testo statisticamente probabile, ma al contempo contenente un messaggio segreto decodificabile. La decodifica è resa possibile, tuttavia, solo a condizione che il destinatario sia a conoscenza della tecnica impiegata e disponga di una chiave privata condivisa con il mittente, elemento cruciale per garantire la sicurezza e la recuperabilità delle informazioni nascoste, oltre che del modello linguistico utilizzato per la generazione del testo. In questo modo, *Meteor* si posiziona come un sistema di comunicazione segreta che sfrutta le capacità generative dei modelli linguistici per nascondere informazioni in piena vista, rendendo computazionalmente impossibile per un osservatore esterno identificare o decifrare il messaggio nascosto.

Costruiamo ora uno scenario illustrativo, volto a consolidare in modo approfondito la comprensione del meccanismo operativo di *Meteor* e, più in generale, dei principi fondamentali della steganografia generativa. Immaginiamo una comunicazione confidenziale tra due entità distinte, Alice (A) e Bob (B), che desiderano scambiarsi informazioni sensibili con la massima discrezione. L'obiettivo primario di questa precauzione è impedire a un potenziale osservatore esterno, qui identificato come Eve (E), di intercettare, decifrare o persino riconoscere la natura confidenziale del contenuto del messaggio. Un contesto d'uso particolarmente pertinente e diffuso che rende necessaria l'adozione di tecniche steganografiche avanzate si verifica quando Alice o Bob operano all'interno di una rete di comunicazione o di un sistema autonomo soggetto a un controllo

governativo particolarmente stringente. Tali sistemi spesso implementano estese forme di filtraggio dei contenuti, basate su sofisticate analisi dei messaggi che transitano al loro interno. In circostanze così restrittive, messaggi che sono stati opportunamente cifrati, ovvero dotati di crittografia, hanno la "vulnerabilità" di essere facilmente identificabili come tali e quindi facilmente filtrabili dai gestori dei nodi della rete (Figura 1). Un esempio emblematico di tale scenario è rappresentato dal sistema citato in [ENS+15], comunemente noto come il "China's Great Firewall". Questo imponente sistema esercita un controllo significativo sui gestori di rete e sul traffico dati, operando spesso attraverso meccanismi non trasparenti o del tutto ignoti all'utente finale¹. All'interno di un quadro operativo marcatamente ostile come questo, la steganografia generativa si propone di superare il problema fondamentale del rilevamento. L'obiettivo è permettere ad Alice e Bob di comunicare in modo intrinsecamente "segreto", impedendo a Eve di etichettare la comunicazione come anomala, sospetta o meritevole di attenzione speciale².

La metodologia cardine, che costituisce l'ossatura del framework *Meteor*, consiste, dunque, nell'impiegare in modo strategico un modello generativo avanzato. Questo modello è incaricato della creazione di un testo che possessa una doppia caratteristica essenziale: da un lato, deve essere statisticamente indistinguibile da un testo prodotto naturalmente, apparendo quindi plausibile e privo di anomalie; dall'altro, deve veicolare al suo interno, in maniera nascosta e decodificabile, un messaggio segreto. Questo approccio garantisce che, anche qualora Eve dovesse intercettare la comunicazione, le sarebbe impossibile identificarla come un potenziale contenitore di informazioni nascoste. Ciò è dovuto al fatto che il testo generato apparirebbe come un output linguisticamente coerente, semanticamente valido e statisticamente plausibile, rendendolo virtualmente indistinguibile da qualsiasi altro testo prodotto spontaneamente. L'efficacia di tale indistinguibilità aumenta quanto più avanzato è il modello linguistico utilizzato, specialmente se questo è capace di rappresentare

1 È importante sottolineare che limitazioni significative alla libertà di comunicazione non sono state prerogativa esclusiva di specifici contesti geopolitici, ma sono state osservate e attuate anche da governi appartenenti alla sfera occidentale o da entità private. A tale riguardo, si rimanda alle analisi presentate in [CON16; SAB25; SUA26; EUR].

2 È importante sottolineare che, in contesti operativi simili, il termine "segreto" può avere connotazioni negative, suggerendo attività clandestine illecite o non etiche. Tuttavia, nel presente scenario, "segreto" e "privato" sono usati in modo quasi sinonimico. Una comunicazione è considerata segreta se non viene intercettata o compresa da terzi, e privata se solo i destinatari designati possono interpretarne il contenuto, garantendo così l'esclusività dell'accesso all'informazione.

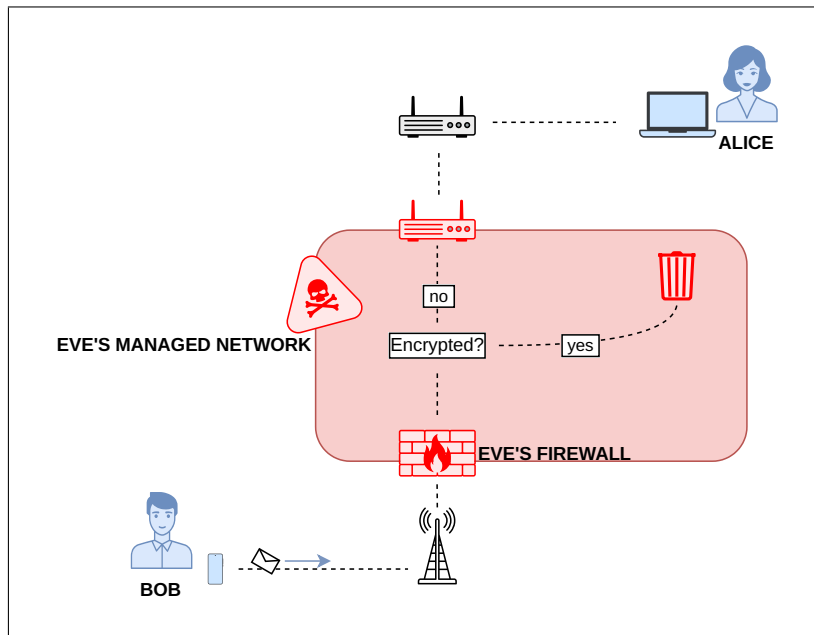


Figura 1: Rappresentazione schematica di una comunicazione tra Alice (A) e Bob (B) in presenza di un osservatore esterno, Eve (E), e di un sistema di filtraggio dei contenuti, come un firewall governativo, progettato per monitorare e bloccare il traffico sospetto.

fedelmente le intricate sfumature del linguaggio naturale.

Dal punto di vista teorico, *Meteor* definisce un protocollo di comunicazione sicura e resiliente, progettato per operare in ambienti ostili. La progettazione e l'implementazione del sistema hanno affrontato due sfide principali.

La prima criticità riguarda l'individuazione di un adeguato *sampler steganografico*. Tale algoritmo deve selezionare, dato un contesto testuale, un token che sia non solo semanticamente coerente, ma anche conforme alla distribuzione di probabilità del linguaggio naturale. Gli autori hanno affrontato il problema impiegando i Large Language Models (LLM) che, pur non costituendo un modello perfetto del linguaggio, rappresentano lo stato dell'arte nella stima delle distribuzioni probabilistiche testuali. Inoltre, la possibilità di specializzare tali modelli su stili linguistici specifici incrementa significativamente la plausibilità dei messaggi generati.

La seconda sfida è legata alla variabilità dell'entropia nel linguaggio naturale. In contesti caratterizzati da entropia estremamente bassa, la libertà di scelta del token successivo è minima; ad esempio, in una sequenza come "*The largest carnivore of the Cretaceous period was the Tyrannosaurus*", il token successivo è quasi deterministicamente "Rex". In tali scenari, l'in-

serimento di informazione segreta comprometterebbe inevitabilmente la naturalezza del testo. Il framework *Meteor* risolve questo problema adottando una strategia di codifica adattiva: il sistema evita deliberatamente l’inserimento di dati nelle posizioni a bassa entropia. Di conseguenza, la quantità di informazione codificata per singolo token diventa variabile, permettendo di massimizzare il throughput complessivo senza degradare la qualità statistica e la plausibilità del segnale steganografico.

BIBLIOGRAFIA

- [EUR] European Pirate Party. *Chat control 2.0: the sequel nobody asked for*. URL: <https://europeanpirates.eu/chatcontrol-the-sequel-nobody-asked-for/> (cit. a p. 13).
- [KAP+] Gabriel Kaptchuk et al. *Meteor. Cryptographically secure steganography for realistic distributions*. URL: <https://meteorfrom.space/> (visitato il giorno 10/07/2025).
- [SHA] Adrian Shahbaz. *The rise of digital authoritarianism*. URL: <https://freedomhouse.org/report/freedom-net/2018/rise-digital-authoritarianism>.
- [SUA26] Matteo Suanno. «Cosa significa che Starlink non è più accessibile all'esercito russo in Ucraina». In: (6 feb. 2026). URL: <https://www.wired.it/article/cosa-sappiamo-blocco-starlink-militari-ucraina/> (cit. a p. 13).
- [BS25] Dave Bergmann e Cole Stryker. *Diffusion models*. 17 Apr. 2025. URL: <https://www.ibm.com/think/topics/diffusion-models> (visitato il giorno 10/07/2025).
- [SAB25] Wisdom Sablah. *WhatsApp Banned Countries List & How to Bypass the Ban* 2026. 13 Nov. 2025. URL: <https://www.cloudwards.net/countries-where-whatsapp-is-banned/> (cit. a p. 13).
- [XU+25] Yuhua Xu et al. «Approximate Gaussian Mapping for Generative Image Steganography». In: *arXiv preprint arXiv:2510.07219* (2025).
- [APA+24] Richard Apau et al. «Image steganography techniques for resisting statistical steganalysis attacks: A systematic literature review». In: *PLOS ONE* 19.9 (set. 2024), pp. 1–47. DOI: [10.1371/journal.pone.0308807](https://doi.org/10.1371/journal.pone.0308807). URL: <https://doi.org/10.1371/journal.pone.0308807>.
- [LI+24] Li Li et al. «Image Steganography and Style Transformation Based on Generative Adversarial Network». In: *Mathematics* 12.4 (2024). ISSN: 2227-7390. DOI: [10.3390/math12040615](https://doi.org/10.3390/math12040615). URL: <https://www.mdpi.com/2227-7390/12/4/615>.

- [SCA24] Simone Scardapane. *Alice's Adventures in a Differentiable Wonderland – Volume I, A Tour of the Land*. 26 Apr. 2024. URL: <https://arxiv.org/abs/2404.17625>.
- [BER23] Giulia Bertazzini. «An overview of Diffusion Models in Multimedia Forensics: Generating and Detecting Synthetic Images». 27 Ott. 2023.
- [ERD23] Kemal Erdem. *Step by step visual introduction to diffusion models*. Nov. 2023. URL: <https://erdem.pl/2023/11/step-by-step-visual-introduction-to-diffusion-models> (visitato il giorno 10/07/2025).
- [BOU22] Daniel Bourke. *Learn PyTorch for deep learning in a day. Literally*. 24 Lug. 2022. URL: https://www.youtube.com/watch?v=Z_ikDlimN6A.
- [GU+21] Shuyang Gu et al. «Vector Quantized Diffusion Model for Text-to-Image Synthesis». In: *CoRR* abs/2111.14822 (2021). arXiv: 2111.14822. URL: <https://arxiv.org/abs/2111.14822>.
- [KAP+21] Gabriel Kaptchuk et al. *Meteor: Cryptographically Secure Steganography for Realistic Distributions*. Cryptology ePrint Archive, Paper 2021/686. 2021. URL: <https://eprint.iacr.org/2021/686> (cit. a p. 11).
- [SUB+21] Nandhini Subramanian et al. «Image Steganography: A Review of the Recent Advances». In: *IEEE Access* 9 (2021), pp. 23409–23423. DOI: [10.1109/ACCESS.2021.3053998](https://doi.org/10.1109/ACCESS.2021.3053998).
- [WEN21] Lilian Weng. *What are Diffusion Models?* 11 Lug. 2021. URL: <https://lilianweng.github.io/posts/2021-07-11-diffusion-models/>.
- [ERO20] Patrick Esser, Robin Rombach e Björn Ommer. «Taming Transformers for High-Resolution Image Synthesis». In: *CoRR* abs/2012.09841 (2020). arXiv: 2012.09841. URL: <https://arxiv.org/abs/2012.09841>.
- [LIU+20] Jia Liu et al. «Recent Advances of Image Steganography With Generative Adversarial Networks». In: *IEEE Access* 8 (2020), pp. 60575–60597. DOI: [10.1109/ACCESS.2020.2983175](https://doi.org/10.1109/ACCESS.2020.2983175).
- [ZHA+19] Zhuo Zhang et al. «Generative Steganography by Sampling». In: *IEEE Access* 7 (2019), pp. 118586–118597. DOI: [10.1109/ACCESS.2019.2920313](https://doi.org/10.1109/ACCESS.2019.2920313).

- [HU+18] Donghui Hu et al. «A Novel Image Steganography Method via Deep Convolutional Generative Adversarial Networks». In: *IEEE Access* 6 (2018), pp. 38303–38314. doi: [10.1109/ACCESS.2018.2852771](https://doi.org/10.1109/ACCESS.2018.2852771).
- [CON16] Kate Conger. *WhatsApp blocked in Brazil again*. 19 Lug. 2016. URL: <https://techcrunch.com/2016/07/19/whatsapp-blocked-in-brazil-again/> (cit. a p. 13).
- [ENS+15] Roya Ensafi et al. «Examining How the Great Firewall Discovers Hidden Circumvention Servers». In: *Proceedings of the 2015 Internet Measurement Conference*. IMC '15. Tokyo, Japan: Association for Computing Machinery, 2015, pp. 445–458. ISBN: 9781450338486. doi: [10.1145/2815675.2815690](https://doi.org/10.1145/2815675.2815690). URL: <https://doi.org/10.1145/2815675.2815690> (cit. a p. 13).