



UNIVERSITÀ
DEGLI STUDI
FIRENZE

Scuola di Scienze Matematiche, Fisiche e Naturali
Corso di Laurea in Informatica

Tesi di Laurea

STEGANOGRAFIA GENERATIVA SU
IMMAGINI:
ADATTAMENTO DEL PROTOCOLLO METEOR
TRAMITE L'ARCHITETTURA VQ-GAN

GENERATIVE IMAGE STEGANOGRAPHY:
ADAPTING THE METEOR PROTOCOL TO THE
VQ-GAN ARCHITECTURE

MATTEO DICIOTTI

Relatore: Prof. *Daniele Baracchi*

Correlatrice: PhD *Giulia Bertazzini*

Correlatore: Prof. *Daniele Castellana*

Anno Accademico 2024-2025

Matteo Diciotti: *Steganografia generativa su immagini:*
adattamento del protocollo Meteor tramite l'architettura VQ-GAN, Corso di
Laurea in Informatica, © Anno Accademico 2024-2025

INDICE

Elenco delle figure	3
1 Introduzione	7
2 Stato dell'arte	11
2.1 Meteor: un framework di steganografia generativa per il testo	11
2.1.1 Meccanismo Operativo del Protocollo Meteor . . .	15
2.2 VQ-GAN: generazione di immagini ad alta risoluzione . .	19
Bibliografia	21

ELENCO DELLE FIGURE

Figura 1	Alice e Bob attraversano il firewall di Eve	13
----------	---	----

"Questo è bello!"
"Eh, nella sua semplicità.."
"Questo è iper-realista."
"E se me lo concedi monocromatico."
"L'artista è Meteor."
"Meteor, già sentito!"
— Aldo, Giovanni e Giacomo

INTRODUZIONE

L'esigenza intrinseca e crescente di garantire comunicazioni che siano contemporaneamente riservate, autentiche e integre rappresenta un pilastro fondamentale su cui si erge l'architettura stessa del mondo digitale contemporaneo. La sicurezza delle informazioni, in passato, è stata prevalentemente affidata a robuste tecniche crittografiche e a protocolli standard ben consolidati, quali il Transport Layer Security (TLS) e il suo predecessore Secure Sockets Layer (SSL). Questi sistemi sono stati meticolosamente progettati per rendere il contenuto effettivo dei messaggi inaccessibile a qualsiasi entità esterna non in possesso delle chiavi di decifratura appropriate; nel contesto di TLS, ciò si traduce tipicamente nell'esclusione di chiunque non partecipi al processo di negoziazione della connessione (l'handshake).

Tuttavia, l'escalation senza precedenti delle misure di sorveglianza di massa su scala globale e la proliferazione di meccanismi di censura sempre più capillari e sofisticati hanno messo a nudo una vulnerabilità critica, intrinseca e finora difficile da eradicare alla crittografia moderna: la sua stessa visibilità. Sebbene la crittografia riesca efficacemente a mantenere segreto il contenuto dei dati trasmessi, l'elevata entropia e le caratteristiche distintive del traffico cifrato lo rendono facilmente identificabile e distinguibile dalle comunicazioni in chiaro. Questo stato di cose consente a regimi autoritari, a entità statali o a sofisticati sistemi di filtraggio di rete (come i firewall avanzati) di individuare, bloccare o degradare selettivamente le comunicazioni protette, compromettendo così l'effettivo scambio di informazioni sensibili in contesti operativi ostili o sorvegliati.

Di fronte a tali sfide, specialmente in scenari caratterizzati da censura estrema o da ambienti di comunicazione altamente avversari, emerge in modo prepotente la necessità di esplorare e impiegare metodologie steganografiche. La steganografia, come disciplina, si dedica all'arte e alla scienza dell'occultamento di informazioni segrete all'interno di oggetti

di copertura (cover objects) che, a un'osservazione superficiale, appaiono del tutto innocui e non sospetti. Questi oggetti di copertura possono assumere svariate forme, tra cui testi, immagini, file audio o video. A differenza della crittografia, il cui successo e la cui sicurezza dipendono in larga misura dalla complessità matematica o computazionale necessaria per decifrare il messaggio cifrato, la sicurezza in ambito steganografico poggia su un principio radicalmente diverso: l'indistinguibilità statistica. L'obiettivo primario è fare in modo che un osservatore esterno non sia minimamente in grado di discriminare tra un oggetto che contiene un messaggio segreto (denominato stego-object) e un oggetto analogo che ne è privo.

Le metodologie steganografiche classiche, quali ad esempio la manipolazione dei bit meno significativi (Least Significant Bit - LSB) nelle immagini digitali, si sono progressivamente rivelate vulnerabili agli attacchi di crittoanalisi statistica sempre più avanzati e raffinati. Per superare queste limitazioni intrinseche e garantire un livello di sicurezza che sia non solo robusto ma anche dimostrabile, la ricerca più recente ha abbracciato un vero e proprio cambio di paradigma. Questo nuovo orientamento si concentra sull'utilizzo strategico di modelli generativi, in particolare quelli basati su reti neurali profonde.

In questo fertile contesto di ricerca si inserisce **Meteor**, un innovativo algoritmo di steganografia a chiave simmetrica. Meteor sfrutta le potenti capacità computazionali e generative dei modelli di linguaggio di grandi dimensioni (Large Language Models - LLM), originariamente derivati da architetture come GPT-2, per creare canali di comunicazione occulti e resilienti. A differenza delle tecniche steganografiche tradizionali che modificano un contenuto esistente, Meteor interviene e guida il processo di generazione stessa del contenuto. Esso utilizza la distribuzione di probabilità intrinseca del modello generativo per "pilotare" il campionamento dei token successivi in base al messaggio segreto opportunamente cifrato. Questo approccio garantisce che lo stego-object risultante sia statisticamente coerente e indistinguibile dall'output naturale del modello, rendendo la presenza del messaggio nascosto estremamente difficile, se non impossibile, da rilevare attraverso analisi statistiche convenzionali.

L'ambizioso obiettivo della presente tesi triennale è estendere il principio fondamentale di sicurezza steganografica ideato da Meteor, originariamente applicato al dominio testuale, all'ambito delle immagini digitali ad alta risoluzione. Per conseguire questo scopo, viene sfruttata l'architettura **VQ-GAN** (Vector Quantized Generative Adversarial Network). La scelta strategica di questa specifica architettura deriva dalla

sua intrinseca capacità di modellare immagini estremamente complesse attraverso la creazione e l'utilizzo di un vocabolario discreto di "token visivi", memorizzati in un codebook. Questa rappresentazione discreta apre le porte all'applicazione di un modello Transformer autoregressivo, ampiamente utilizzato nella generazione sequenziale, per guidare il processo di sintesi dell'immagine. Il lavoro svolto mira dunque a dimostrare con rigore e sperimentazione come sia possibile incorporare messaggi cifrati direttamente durante la fase di generazione dell'immagine da parte dell'architettura VQ-GAN. L'obiettivo finale è ottenere immagini non solo visivamente simili a quelle generate dallo stesso modello, ma anche intrinsecamente robuste contro tentativi sofisticati di rilevamento steganografico.

Le implicazioni pratiche e teoriche di questo approccio sono potenzialmente rivoluzionarie per lo sviluppo di strumenti di comunicazione *copyright-resistant*. La capacità di abilitare lo scambio sicuro e nascosto di informazioni all'interno di immagini di alta qualità offre un livello inedito di protezione per la privacy degli utenti e per la libertà di espressione in contesti digitali sempre più soggetti a sorveglianza e controllo.

Il presente elaborato è stato organizzato con cura per condurre il lettore attraverso un percorso logico e approfondito, dalla teoria alla pratica:

- Il **Capitolo 2** fornisce un'analisi completa e dettagliata del background teorico indispensabile, approfondendo lo stato dell'arte delle tecniche steganografiche esistenti e i principi fondamentali di funzionamento dei modelli generativi più avanzati, con un'enfasi particolare sulle architetture GAN (Generative Adversarial Networks) e Transformer.
- Il **Capitolo 3** presenta le definizioni formali e le specifiche tecniche del sistema proposto, illustrando in dettaglio l'architettura implementata e le modifiche apportate al meccanismo di campionamento dei token visivi per consentire l'embedding del messaggio segreto cifrato direttamente nel flusso generativo. Vengono inoltre discussi i limiti teorici e pratici del lavoro svolto, evidenziando le sfide affrontate e le soluzioni adottate per superarle.
- Il **Capitolo 4** presenta l'idea alla base del lavoro di tesi, l'architettura completa del sistema implementato e i limiti teorici e pratici del lavoro svolto. Vengono illustrate in dettaglio le modifiche apportate al meccanismo di campionamento dei token visivi per consentire

l'embedding del messaggio segreto cifrato direttamente nel flusso generativo.

- Il **Capitolo 5** espone in modo esaustivo i risultati delle sperimentazioni condotte. Vengono valutate sia la qualità visiva delle immagini generate, attraverso l'utilizzo di metriche consolidate come la Fréchet Inception Distance (FID), sia la capacità steganografica del sistema, analizzando il payload trasferibile e la robustezza contro attacchi di rilevamento.
- Infine, il **Capitolo 6** trae le conclusioni finali del lavoro svolto, riassumendo i contributi principali della ricerca e delineando una serie di possibili sviluppi futuri, mirati al miglioramento incrementale dell'efficienza, della robustezza e della sicurezza complessiva del sistema proposto.

STATO DELL'ARTE

2.1 METEOR: UN FRAMEWORK DI STEGANOGRAFIA GENERATIVA PER IL TESTO

La necessità di una solida comprensione teorica, indispensabile per contestualizzare appieno il presente lavoro di ricerca, si articola attraverso una costellazione di concetti interdipendenti che convergono in un'unica opera fondamentale: il lavoro di [KAP+21], comunemente noto come *Meteor*. Questa pionieristica indagine, che va oltre una mera disamina della steganografia classica e di quella generativa, introduce primariamente un approccio metodologico e, in secondo luogo, un framework robusto ed efficiente deputato alla *generazione di messaggi testuali contenenti informazioni celate*.

La peculiarità di queste informazioni risiede nella loro intrinseca invisibilità non solo all'occhio umano, ma anche, e soprattutto, alle più sofisticate tecniche di steganalisi basate su divergenza statistica. La ragione di tale elusività risiede nella formalizzazione del concetto di *perfectly secure steganography* nel dominio del linguaggio naturale: il testo generato da *Meteor* non manifesta alcuna deviazione statistica significativa rispetto a un testo prodotto autonomamente dal medesimo modello linguistico di base (il cosiddetto *cover distribution*). Come verrà dettagliato in seguito, *Meteor* si avvale di un modello linguistico che ha raggiunto una notevole notorietà, estendendosi ben oltre gli ambiti accademici tradizionali, configurandosi come uno dei primi Transformer a larga scala a influenzare il dibattito pubblico sulla capacità generativa delle IA. Nello specifico, *Meteor* impiega il modello **GPT-2** (Generative Pre-trained Transformer 2), caratterizzato da un'architettura *decoder-only* addestrata su un corpus massivo di dati testuali (WebText). Tuttavia, l'architettura del framework è stata concepita con una notevole flessibilità, risultando agnostica rispetto al modello linguistico sottostante (*Backbone LLM*). Questa modularità permette a *Meteor* di beneficiare direttamente dei progressi nello stato

dell'arte dei modelli linguistici, poiché l'efficacia della steganografia è intrinsecamente legata alla capacità del modello di approssimare la vera distribuzione del linguaggio umano (P_{data}).

Per una comprensione ancora più profonda, è opportuno esaminare il contesto socio-tecnologico in cui *Meteor* è maturato e le problematiche specifiche che si proponeva di risolvere, con particolare attenzione alla crescente sofisticazione dei sistemi di sorveglianza e censura digitale. In un'epoca in cui la libertà di espressione e la privacy online sono costantemente minacciate da regimi autoritari e da sistemi di filtraggio sempre più avanzati, la necessità di strumenti di comunicazione *censorship-resistant* è diventata più urgente che mai. *Meteor* si inserisce in questo contesto come una risposta innovativa, offrendo un metodo per nascondere informazioni all'interno di testi generati in modo naturale, rendendo estremamente difficile per qualsiasi osservatore esterno rilevare la presenza di un messaggio segreto.

L'essenza di *Meteor* risiede nell'idea innovativa di utilizzare un modello generativo per la creazione di contenuti steganografici, sfruttando la sua capacità di modellare la probabilità condizionata $P(x_t|x_{<t})$. In termini pratici, il modello agisce come un sofisticato stimatore di densità: data una sequenza di contesto iniziale (*prompt*), esso fornisce una distribuzione di probabilità dettagliata (solitamente tramite una funzione *softmax* applicata ai *logits*) per tutti i possibili *token* contenuti nel vocabolario $\mathcal{V}$. La scelta del *token* da inserire nella sequenza viene effettuata tramite un meccanismo di campionamento che mappa i bit del messaggio segreto in indici del vocabolario, seguendo l'ordinamento indotto dalla distribuzione di probabilità. Questa metodologia trasforma il processo di inferenza in un'operazione di codifica di canale: il testo risultante è statisticamente probabile secondo il modello, ma contiene un messaggio segreto decodificabile univocamente dal destinatario. La decodifica è resa possibile a condizione che il ricevente disponga dello stesso modello linguistico, della medesima sequenza di contesto e di una chiave privata condivisa (*shared secret*), necessaria per inizializzare il generatore di numeri pseudo-casuali o per definire le permutazioni degli indici del vocabolario.

Costruiamo ora uno scenario illustrativo volto a consolidare la comprensione del meccanismo operativo di *Meteor*. Immaginiamo una comunicazione confidenziale funzionamento tra due entità, Alice (A) e Bob (B), che desiderano scambiarsi informazioni sensibili attraverso un canale pubblico monitorato. L'obiettivo primario è impedire a un osservatore avversario, Eve (E), di rilevare la presenza stessa della comunicazione (*ste-*

ganographic undetectability). Un contesto critico si verifica quando Alice o Bob operano all'interno di infrastrutture soggette a *Deep Packet Inspection* (DPI) o filtraggio governativo stringente. In tali scenari, i messaggi cifrati tramite crittografia standard (come AES o RSA) presentano un'elevata entropia e caratteristiche distintive che li rendono facilmente identificabili come traffico cifrato, risultando facilmente identificabili come traffico non lecito e quindi soggetto a blocco immediato (Figura 1). Un esempio emblematico è il sistema descritto in [ENS+15], il "*Great Firewall*", che impiega euristiche avanzate per discriminare tra traffico legittimo e protocolli di tunneling o cifratura. All'interno di questo quadro ostile, la steganografia generativa supera il limite della crittografia tradizionale: non si limita a proteggere il contenuto, ma nasconde l'esistenza stessa dell'atto comunicativo. Eve, osservando il transito di un testo coerente e stilisticamente appropriato, non ha basi statistiche per etichettare la comunicazione come sospetta¹.




Figura 1: Rappresentazione schematica di una comunicazione tra Alice (A) e Bob (B) in presenza di un osservatore esterno, Eve (E), e di un sistema di filtraggio dei contenuti (Firewall) che analizza la firma statistica dei pacchetti.

Sotto il profilo teorico, la progettazione di *Meteor* ha richiesto la risoluzione di due criticità fondamentali intrinseche alla natura del linguaggio

¹ Nel presente scenario, "segreto" e "privato" sono usati in senso tecnico: una comunicazione è steganograficamente sicura se la divergenza di Kullback-Leibler tra la distribuzione dei messaggi naturali e quella dei messaggi steganografici tende a zero.

naturale.

La prima sfida concerne la definizione di un *sampler steganografico* efficace. L'algoritmo deve mappare il contesto fornito al modello in una distribuzione di probabilità del token successivo che ricalchi quanto più fedelmente possibile quella del linguaggio naturale. Risulta tuttavia evidente che il linguaggio naturale non sottostia a una distribuzione di probabilità assoluta e invariante: si considerino, a titolo esemplificativo, le divergenze linguistiche intercorrenti tra un testo dei primi del Novecento e uno contemporaneo, o tra la prosa scientifica e quella letteraria. *Meteor* affronta tale complessità adottando un modello di generazione testuale come approssimatore dinamico del linguaggio naturale. Tale approccio consente di simulare efficacemente la distribuzione linguistica in molteplici domini, superando il problema dell'assenza di una distribuzione statistica universale che ha storicamente limitato la steganografia classica. È tuttavia opportuno precisare che l'efficacia di *Meteor* è intrinsecamente dipendente dalla capacità del modello linguistico sottostante (il *Backbone LLM*) di approssimare la distribuzione reale. Qualora il modello non riuscisse a catturare le sfumature e le complessità semantiche del linguaggio umano, la steganografia generativa diverrebbe vulnerabile a tecniche di rilevamento avanzate. Cionondimeno, ogni output prodotto da *Meteor* risulta statisticamente indistinguibile da un testo generato autonomamente dal medesimo modello; ciò garantisce una sicurezza steganografica assoluta, a condizione che non sia possibile distinguere tra un testo prodotto dal modello e uno naturale.

La seconda sfida è legata alla variabilità dell'entropia testuale. In segmenti caratterizzati da elevata densità semantica o vincoli sintattici stringenti (bassa entropia), la libertà di selezione del token successivo è pressoché nulla. Ad esempio, data la sequenza "*The largest carnivore of the Cretaceous period was the Tyrannosaurus*", il "token" "*Rex*" presenta una probabilità estremamente elevata. Forzare la codifica di bit in tale posizione selezionando un token alternativo produrrebbe un'anomalia semantica macroscopica, facilmente individuabile da un classificatore neurale. Per ovviare a ciò, *Meteor* introduce una soglia di entropia minima: il sistema analizza la distribuzione di probabilità a ogni passo temporale e determina dinamicamente se la varianza sia sufficiente per ospitare informazione. Se l'entropia è inferiore a un valore critico τ , il sistema genera un token senza inserire informazione steganografica. Qualora, invece, l'entropia superi tale soglia, il sistema seleziona i token con probabilità rilevanti, escludendo la coda della distribuzione. Attraverso un meccanismo di partizionamento degli indici basato sulle probabilità relative, viene

campionato il token i cui estremi dell'intervallo di probabilità presentino una corrispondenza tra i bit più significativi e i bit del messaggio da codificare. Nel caso in cui l'intervallo non permetta la codifica di alcun bit (ovvero quando gli estremi non condividono il prefisso binario), *Meteor* adotta una strategia a bitrate variabile, rinunciando all'inserimento di informazione per quel determinato passo. In fase di decodifica, la conoscenza della distribuzione di probabilità e dei relativi indici consente di determinare univocamente se l'informazione sia stata inserita o meno, ponendo recuperare l'intervallo relativo al token selezionato e recuperando i bit più significativi comuni per tutti i valori nell'intervallo. Sebbene tale eventualità sia rara data l'elevata entropia media del linguaggio, questa strategia di codifica adattiva (*adaptive rate*) garantisce che il throughput informativo sia massimizzato esclusivamente dove il linguaggio offre una ridondanza naturale, preservando rigorosamente l'integrità statistica del testo prodotto.

2.1.1 Meccanismo Operativo del Protocollo Meteor

Il concetto fondamentale che differenzia Meteor dai metodi tradizionali di steganografia è lo spostamento del paradigma: l'informazione non viene "nascosta" all'interno di un oggetto esistente tramite modifiche (embedding), ma viene utilizzata per **guidare il processo di campionamento** durante la generazione di un nuovo media [1, 3].

Il funzionamento pratico del protocollo si articola nelle seguenti fasi sequenziali:

1. **Cifratura del Messaggio:** Il messaggio segreto viene cifrato utilizzando una chiave simmetrica condivisa tra mittente e destinatario. Questo passaggio è essenziale per trasformare il messaggio in una stringa di bit computazionalmente indistinguibile dal rumore casuale, garantendo che le scelte di campionamento effettuate dal protocollo non presentino pattern statistici rilevabili.
2. **Accesso alla Distribuzione Condizionata:** Meteor si appoggia a un modello generativo pre-addestrato (originariamente GPT-2 per il testo, un'architettura basata su Transformers, necessità principale anche per lo sviluppo di modelli per il dominio visivo come nel caso della VQ-GAN che verederemo nl seguito). Ad ogni passo temporale t , il modello riceve il contesto dei token già generati e produce una **distribuzione di probabilità P** su tutto il vocabolario dei possibili token successivi.

3. **Campionamento Vincolato (Embedding):** Invece di campionare casualmente o scegliere il token più probabile, Meteor utilizza i bit del messaggio cifrato come "indice" per selezionare il token dalla distribuzione P . Lo spazio di probabilità viene partizionato e mappato sulle sequenze di bit in modo che il token scelto sia sempre **statisticamente coerente** con il modello originale. Poiché la scelta avviene all'interno della distribuzione naturale del modello, l'output steganografico rimane visivamente (o testualmente) indistinguibile da un output generato normalmente dallo stesso modello.
4. **Generazione Iterativa:** Questo processo avviene in modo autoregressivo. Ogni token generato entra a far parte del nuovo contesto per il passo successivo, continuando fino a quando l'intero media (o la sequenza di token visivi necessari per ricostruire l'immagine tramite il decoder VQ-GAN) non è completo.
5. **Estrazione e Decodifica:** Il ricevente, possedendo lo stesso modello generativo e la chiave simmetrica, è in grado di ricreare le medesime distribuzioni di probabilità P per ogni passo del processo. Identificando quali token sono stati effettivamente inclusi nello stego-media ricevuto, il destinatario può risalire ai bit che hanno determinato quelle scelte, ricostruendo il messaggio cifrato e, infine, il segreto originale.

L'efficacia di Meteor risiede nella sua capacità di eliminare le anomalie statistiche che gli strumenti di **steganalisi moderna** solitamente identificano. In questo contesto, il messaggio segreto non è contenuto "nei" dati, ma rappresenta la **ragione deterministica** per cui determinati dati coerenti sono stati generati al posto di altri.

Per comprendere appieno il flusso del protocollo, è utile illustrare uno scenario concreto². Supponiamo che Alice voglia comunicare con il compagno Bob senza che sua madre Eve, esperta di reti di telecomunicazioni e ostile alla loro relazione, lo venga a sapere. Alice ha dimenticato il proprio computer a casa di Bob e deve chiedergli di riportarglielo, ma Eve intercetta ogni comunicazione all'interno della rete domestica. In questo scenario, Alice ha esaurito il traffico dati cellulare e non ha accesso a reti Wi-Fi alternative. Il firewall di casa è stato configurato da Eve per

2 L'esempio proposto rappresenta una forzatura narrativa volta a evitare i classici scenari di sorveglianza bellica o regimi autoritari. Sebbene la trama possa apparire singolare, ogni passaggio tecnico descritto riflette operazioni realmente attuabili a livello pratico.

bloccare qualsiasi traffico crittografato end-to-end; i messaggi devono transitare in chiaro per poter superare il gateway. La navigazione esterna è mediata da un proxy che instrada le informazioni tramite un protocollo, ideato dalla stessa Eve, che lascia i contenuti leggibili. Di conseguenza, ogni messaggio inviato o ricevuto da Alice è potenzialmente visibile a sua madre.

In questo contesto, qualsiasi comunicazione cifrata in forma tradizionale verrebbe immediatamente bloccata. Alice e Bob decidono quindi di utilizzare *Meteor*. Alice redige un messaggio segreto: «Mi porteresti il portatile domani per favore, l'ho lasciato sul tavolo di cucina da te.». Utilizzando una chiave simmetrica condivisa (ad esempio la data del loro anniversario), cifra il testo ottenendo una stringa di bit. Il messaggio originale, lungo 88 caratteri in codifica ASCII, corrisponde a 88 byte, ovvero 704 bit. Dopo la cifratura, si ottiene una sequenza di 704 bit indistinguibile dal rumore casuale. Poiché l'invio diretto di tale stringa verrebbe intercettato e bloccato da Eve, Alice si affida a *Meteor* per trasformarla.

Eve è abituata a vedere Alice e Bob scambiarsi testi generati da modelli linguistici mentre studiano insieme per l'università. Alice, studentessa di ingegneria informatica, decide di sfruttare questa abitudine: sa che Eve non sospetterà nulla se vedrà transitare nella chat una serie di messaggi relativi alla preparazione dell'esame di Analisi II, scambiandoli per normali interazioni con un LLM. Alice inserisce il messaggio cifrato in *Meteor* e fornisce come contesto iniziale (*prompt*) il testo di un esercizio sullo studio del dominio di una funzione. Il framework genererà un testo che non solo nasconde il messaggio cifrato in modo trasparente, ma risulterà anche semanticamente coerente con il contesto matematico fornito.

L'efficienza di questo processo dipende dalla «precisione» di *Meteor*, ovvero dal numero di bit che possono essere codificati in un singolo token. Questo valore è influenzato dalla dimensione del vocabolario e dalla distribuzione di probabilità dei token. Mentre per modelli come GPT-2 è teoricamente possibile codificare fino a 32 bit per token, in media se ne ottengono circa 20. Tuttavia, in contesti a bassa entropia come un esercizio di analisi, la capacità di codifica può scendere sensibilmente. Supponendo uno scenario cautelativo con una capacità di 5 bit per token (con token mediamente composti da 4 caratteri), per codificare i 704 bit del messaggio Alice dovrà generare un testo di circa 140 token (circa 560 caratteri). Tale lunghezza è perfettamente compatibile con una normale risposta di un assistente virtuale.

Per segnalare la fine della comunicazione, può essere utilizzato un

carattere speciale che indichi al destinatario il termine del messaggio. L'output che Eve osserverà sarà simile al seguente:

«Il dominio di una funzione è l'insieme dei valori per i quali la funzione è definita. Ad esempio, se abbiamo la funzione $f(x) = \sqrt{x}$, il dominio è $[0, +\infty)$ perché la radice quadrata è definita solo per numeri non negativi. Se invece abbiamo la funzione $g(x) = \frac{1}{x}$, il dominio è $(-\infty, 0) \cup (0, +\infty)$ perché la divisione per zero non è definita. In generale, per trovare il dominio di una funzione, dobbiamo identificare tutte le restrizioni che potrebbero rendere la funzione non definita, come radici quadrate di numeri negativi o divisioni per zero. Una volta identificate queste restrizioni, possiamo escludere i valori che le violano e determinare il dominio della funzione.»

In questo testo, i token non sono stati scelti tramite un campionamento casuale (*random sampling*) sulla testa della distribuzione, ma per codificare i bit del messaggio segreto. Per ogni passo, *Meteor* ha generato la distribuzione di probabilità tramite il modello linguistico, ha rimosso la coda della distribuzione sotto una soglia prefissata e ha ordinato i *logits* ottenuti. Gli indici, distribuiti proporzionalmente alle probabilità dei token in un intervallo da 0 a 2^p (dove p è la precisione), sono stati usati per selezionare il token i cui bit più significativi corrispondessero ai bit successivi del messaggio cifrato.

Se, ad esempio, i bit da codificare fossero 0101110101... e le distribuzioni di probabilità dei token disponibili coprissero gli intervalli 0001..., 0100..., 0110... e 1010..., *Meteor* selezionerebbe il token associato all'intervallo [0100..., 0110...), codificando i primi due bit (01). Al passaggio successivo, il token selezionato entra a far parte del contesto del modello e i bit codificati vengono rimossi dalla testa del messaggio segreto, procedendo iterativamente fino al completamento o al raggiungimento dei limiti impostati.

Il testo risultante, coerente e naturale, transita sulla rete domestica senza destare sospetti. Bob, ricevendo il messaggio, utilizza lo stesso modello e la medesima chiave per estrarre i bit e decifrare la comunicazione, comprendendo la richiesta di Alice. Grazie a *Meteor*, Alice è riuscita a eludere la sorveglianza di Eve, rendendo la comunicazione indistinguibile da un comune output di un modello linguistico.

2.2 VQ-GAN: GENERAZIONE DI IMMAGINI AD ALTA RISOLUZIONE

Successivamente, analizzeremo le ragioni per cui architetture alternative, come le VQ-GAN (Vector Quantized Generative Adversarial Networks), sono state considerate per l'estensione di tali concetti al dominio visuale.

BIBLIOGRAFIA

- [EUR] European Pirate Party. *Chat control 2.0: the sequel nobody asked for*. URL: <https://europeanpirates.eu/chatcontrol-the-sequel-nobody-asked-for/>.
- [KAP+] Gabriel Kaptchuk et al. *Meteor. Cryptographically secure steganography for realistic distributions*. URL: <https://meteorfrom.space/> (visitato il giorno 10/07/2025).
- [SHA] Adrian Shahbaz. *The rise of digital authoritarianism*. URL: <https://freedomhouse.org/report/freedom-net/2018/rise-digital-authoritarianism>.
- [SUA26] Matteo Suanno. «Cosa significa che Starlink non è più accessibile all'esercito russo in Ucraina». In: (6 feb. 2026). URL: <https://www.wired.it/article/cosa-sappiamo-blocco-starlink-militari-ucraina/>.
- [BS25] Dave Bergmann e Cole Stryker. *Diffusion models*. 17 Apr. 2025. URL: <https://www.ibm.com/think/topics/diffusion-models> (visitato il giorno 10/07/2025).
- [SAB25] Wisdom Sablah. *WhatsApp Banned Countries List & How to Bypass the Ban* 2026. 13 Nov. 2025. URL: <https://www.cloudwards.net/countries-where-whatsapp-is-banned/>.
- [XU+25] Yuhua Xu et al. «Approximate Gaussian Mapping for Generative Image Steganography». In: *arXiv preprint arXiv:2510.07219* (2025).
- [APA+24] Richard Apau et al. «Image steganography techniques for resisting statistical steganalysis attacks: A systematic literature review». In: *PLOS ONE* 19.9 (set. 2024), pp. 1–47. DOI: [10.1371/journal.pone.0308807](https://doi.org/10.1371/journal.pone.0308807). URL: <https://doi.org/10.1371/journal.pone.0308807>.
- [LI+24] Li Li et al. «Image Steganography and Style Transformation Based on Generative Adversarial Network». In: *Mathematics* 12.4 (2024). ISSN: 2227-7390. DOI: [10.3390/math12040615](https://doi.org/10.3390/math12040615). URL: <https://www.mdpi.com/2227-7390/12/4/615>.

- [SCA24] Simone Scardapane. *Alice's Adventures in a Differentiable Wonderland – Volume I, A Tour of the Land*. 26 Apr. 2024. URL: <https://arxiv.org/abs/2404.17625>.
- [BER23] Giulia Bertazzini. «An overview of Diffusion Models in Multimedia Forensics: Generating and Detecting Synthetic Images». 27 Ott. 2023.
- [ERD23] Kemal Erdem. *Step by step visual introduction to diffusion models*. Nov. 2023. URL: <https://erdem.pl/2023/11/step-by-step-visual-introduction-to-diffusion-models> (visitato il giorno 10/07/2025).
- [BOU22] Daniel Bourke. *Learn PyTorch for deep learning in a day. Literally*. 24 Lug. 2022. URL: https://www.youtube.com/watch?v=Z_ikDlimN6A.
- [GU+21] Shuyang Gu et al. «Vector Quantized Diffusion Model for Text-to-Image Synthesis». In: *CoRR* abs/2111.14822 (2021). arXiv: [2111.14822](https://arxiv.org/abs/2111.14822). URL: <https://arxiv.org/abs/2111.14822>.
- [KAP+21] Gabriel Kaptchuk et al. *Meteor: Cryptographically Secure Steganography for Realistic Distributions*. Cryptology ePrint Archive, Paper 2021/686. 2021. URL: <https://eprint.iacr.org/2021/686> (cit. a p. 11).
- [SUB+21] Nandhini Subramanian et al. «Image Steganography: A Review of the Recent Advances». In: *IEEE Access* 9 (2021), pp. 23409–23423. DOI: [10.1109/ACCESS.2021.3053998](https://doi.org/10.1109/ACCESS.2021.3053998).
- [WEN21] Lilian Weng. *What are Diffusion Models?* 11 Lug. 2021. URL: <https://lilianweng.github.io/posts/2021-07-11-diffusion-models/>.
- [ERO20] Patrick Esser, Robin Rombach e Björn Ommer. «Taming Transformers for High-Resolution Image Synthesis». In: *CoRR* abs/2012.09841 (2020). arXiv: [2012.09841](https://arxiv.org/abs/2012.09841). URL: <https://arxiv.org/abs/2012.09841>.
- [LIU+20] Jia Liu et al. «Recent Advances of Image Steganography With Generative Adversarial Networks». In: *IEEE Access* 8 (2020), pp. 60575–60597. DOI: [10.1109/ACCESS.2020.2983175](https://doi.org/10.1109/ACCESS.2020.2983175).
- [ZHA+19] Zhuo Zhang et al. «Generative Steganography by Sampling». In: *IEEE Access* 7 (2019), pp. 118586–118597. DOI: [10.1109/ACCESS.2019.2920313](https://doi.org/10.1109/ACCESS.2019.2920313).

- [HU+18] Donghui Hu et al. «A Novel Image Steganography Method via Deep Convolutional Generative Adversarial Networks». In: *IEEE Access* 6 (2018), pp. 38303–38314. doi: [10.1109/ACCESS.2018.2852771](https://doi.org/10.1109/ACCESS.2018.2852771).
- [CON16] Kate Conger. *WhatsApp blocked in Brazil again*. 19 Lug. 2016. URL: <https://techcrunch.com/2016/07/19/whatsapp-blocked-in-brazil-again/>.
- [ENS+15] Roya Ensafi et al. «Examining How the Great Firewall Discovers Hidden Circumvention Servers». In: *Proceedings of the 2015 Internet Measurement Conference*. IMC '15. Tokyo, Japan: Association for Computing Machinery, 2015, pp. 445–458. ISBN: 9781450338486. doi: [10.1145/2815675.2815690](https://doi.org/10.1145/2815675.2815690). URL: <https://doi.org/10.1145/2815675.2815690> (cit. a p. 13).