



UNIVERSITÀ  
DEGLI STUDI  
FIRENZE

Scuola di Scienze Matematiche, Fisiche e Naturali  
Corso di Laurea in Informatica

Tesi di Laurea

STEGANOGRAFIA GENERATIVA SU  
IMMAGINI:  
ADATTAMENTO DEL PROTOCOLLO METEOR  
TRAMITE L'ARCHITETTURA VQ-GAN

GENERATIVE IMAGE STEGANOGRAPHY:  
ADAPTING THE METEOR PROTOCOL TO THE  
VQ-GAN ARCHITECTURE

MATTEO DICIOTTI

Relatore: Prof. *Daniele Baracchi*

Correlatrice: PhD *Giulia Bertazzini*

Correlatore: Prof. *Daniele Castellana*

Anno Accademico 2024-2025

Matteo Diciotti: *Steganografia generativa su immagini:*  
*adattamento del protocollo Meteor tramite l'architettura VQ-GAN*, Corso di  
Laurea in Informatica, © Anno Accademico 2024-2025

---

## INDICE

---

|                                                         |    |
|---------------------------------------------------------|----|
| Elenco delle figure                                     | 3  |
| 1 Introduzione                                          | 7  |
| 2 Stato dell'arte                                       | 11 |
| 2.1 Meteor                                              | 11 |
| 2.1.1 Contesto e motivazioni                            | 11 |
| 2.1.2 Meccanismo Operativo del Protocollo Meteor        | 15 |
| 2.2 VQ-GAN                                              | 19 |
| 2.2.1 Contesto e motivazioni                            | 19 |
| 2.3 Lavori correlati                                    | 20 |
| 3 Definizioni e terminologia                            | 23 |
| 3.1 Concetti fondazionali della comunicazione           | 23 |
| 3.2 Discipline della comunicazione sicura               | 24 |
| 3.3 Fondamenti di modellazione linguistica              | 25 |
| 3.4 Componenti dei modelli linguistici                  | 26 |
| 3.5 Meccanismi di generazione e controllo               | 26 |
| 3.6 Architetture di reti neurali                        | 27 |
| 3.7 Concetti fondamentali della rappresentazione visiva | 28 |
| 3.8 Architetture per la generazione visuale             | 29 |
| 3.9 Misure e garanzie nei sistemi steganografici        | 29 |
| Bibliografia                                            | 33 |



---

## ELENCO DELLE FIGURE

---

|          |                                                       |    |
|----------|-------------------------------------------------------|----|
| Figura 1 | Alice e Bob attraversano il firewall di Eve . . . . . | 13 |
|----------|-------------------------------------------------------|----|



*"Questo è bello!"*  
*"Eh, nella sua semplicità.."*  
*"Questo è iper-realista."*  
*"E se me lo concedi monocromatico."*  
*"L'artista è Meteor."*  
*"Meteor, già sentito!"*  
*— Aldo, Giovanni e Giacomo*





---

## INTRODUZIONE

---

L'esigenza intrinseca e crescente di garantire comunicazioni che siano contemporaneamente riservate, autentiche e integre rappresenta un pilastro fondamentale su cui si erge l'architettura stessa del mondo digitale contemporaneo. La sicurezza delle informazioni, in passato, è stata prevalentemente affidata a robuste tecniche crittografiche e a protocolli standard ben consolidati, quali il *Transport Layer Security* (TLS) e il suo predecessore *Secure Sockets Layer* (SSL). Questi sistemi sono stati meticolosamente progettati per rendere il contenuto effettivo dei messaggi inaccessibile a qualsiasi entità esterna non in possesso delle chiavi di decifratura appropriate; nel contesto di TLS, ciò si traduce tipicamente nell'esclusione di chiunque non partecipi al processo di negoziazione della connessione (l'handshake).

Tuttavia, l'escalation senza precedenti delle misure di sorveglianza di massa su scala globale e la proliferazione di meccanismi di censura sempre più capillari e sofisticati hanno messo a nudo una vulnerabilità critica, intrinseca e finora difficile da eradicare alla crittografia moderna: la sua stessa visibilità. Sebbene la crittografia riesca efficacemente a mantenere segreto il contenuto dei dati trasmessi, l'elevata entropia e le caratteristiche distintive del traffico cifrato lo rendono facilmente identificabile e distinguibile dalle comunicazioni in chiaro. Questo stato di cose consente a regimi autoritari, a entità statali o a sofisticati sistemi di filtraggio di rete (come i firewall avanzati) di individuare, bloccare o degradare selettivamente le comunicazioni protette, compromettendo così l'effettivo scambio di informazioni sensibili in contesti operativi ostili o sorvegliati.

Di fronte a tali sfide, specialmente in scenari caratterizzati da censura estrema o da ambienti di comunicazione altamente avversari, emerge in modo prepotente la necessità di esplorare e impiegare metodologie steganografiche. La steganografia, come disciplina, si dedica all'arte e alla scienza dell'occultamento di informazioni segrete all'interno di oggetti di

copertura (*cover objects*) che, teoricamente, appaiono del tutto innocui e non sospetti ad un'osservatore esterno. Questi oggetti di copertura possono assumere svariate forme, tra cui testi, immagini, file audio o video. A differenza della crittografia, il cui successo e la cui sicurezza dipendono in larga misura dalla complessità matematica o computazionale necessaria per decifrare il messaggio cifrato, la sicurezza in ambito steganografico poggia su un principio radicalmente diverso: l'indistinguibilità statistica. L'obiettivo primario è fare in modo che un osservatore esterno non sia minimamente in grado di discriminare tra un oggetto che contiene un messaggio segreto (denominato *stego-object*) e un oggetto analogo che ne è privo.

Le metodologie steganografiche classiche, quali ad esempio la manipolazione dei bit meno significativi (*Least Significant Bit* - **LSB**) nelle immagini digitali, si sono progressivamente rivelate vulnerabili agli attacchi di crittoanalisi statistica sempre più avanzati e raffinati. Per superare queste limitazioni intrinseche e garantire un livello di sicurezza che sia non solo robusto ma anche dimostrabile, la ricerca più recente ha abbracciato un vero e proprio cambio di paradigma. Questo nuovo orientamento si concentra sull'utilizzo strategico di modelli generativi, in particolare quelli basati su reti neurali profonde.

In questo fertile contesto di ricerca si inserisce **Meteor**, un innovativo algoritmo di steganografia a chiave simmetrica. Meteor sfrutta le potenti capacità computazionali e generative dei modelli di linguaggio di grandi dimensioni (*Large Language Models* - **LLM**), originariamente derivati da architetture come GPT-2, per creare canali di comunicazione occulti e resilienti. A differenza delle tecniche steganografiche tradizionali che modificano un contenuto esistente, Meteor interviene e guida il processo di generazione stessa del contenuto. Esso utilizza la distribuzione di probabilità intrinseca del modello generativo per "pilotare" il campionamento dei token successivi in base al messaggio segreto opportunamente cifrato. Questo approccio garantisce che lo *stego-object* risultante sia statisticamente coerente e indistinguibile dall'output naturale del modello, rendendo la presenza del messaggio nascosto estremamente difficile, se non impossibile, da rilevare attraverso analisi statistiche convenzionali.

Obiettivo della presente tesi triennale è estendere il principio fondamentale di sicurezza steganografica ideato da Meteor, originariamente applicato al dominio testuale, all'ambito delle immagini digitali ad alta risoluzione, definendo un modello **SwE** (*Steganography without Embedment*). Per conseguire questo scopo, viene sfruttata l'architettura **VQ-GAN** (*Vector Quantized Generative Adversarial Network*). La scelta di tale

architettura deriva dalla sua capacità di modellare immagini estremamente complesse attraverso la creazione e l'utilizzo di un vocabolario discreto di "token visivi", memorizzati in un *codebook*. Questa rappresentazione discreta consente l'applicazione di un modello Transformer autoregressivo, ampiamente utilizzato nella generazione sequenziale, per guidare il processo di sintesi dell'immagine. Il lavoro svolto mira pertanto a dimostrare con rigore e sperimentazione come sia possibile incorporare messaggi cifrati direttamente durante la fase di generazione dell'immagine da parte dell'architettura VQ-GAN. L'obiettivo finale è ottenere immagini non solo visivamente simili a quelle generate dallo stesso modello, ma anche intrinsecamente robuste contro tentativi sofisticati di rilevamento steganografico.

Le implicazioni pratiche e teoriche di questo approccio sono significative per lo sviluppo di strumenti di comunicazione *copyright-resistant*.

Il presente elaborato è stato organizzato per condurre il lettore attraverso un percorso logico e approfondito, percorrendo il seguente schema:

- Il **Capitolo 2** fornisce un'analisi completa e dettagliata del background teorico indispensabile, presentando le architetture di Meteor e VQ-GAN e presentando lo stato dell'arte delle tecniche steganografiche esistenti e i principi fondamentali di funzionamento dei modelli generativi più avanzati.
- Il **Capitolo 3** presenta le definizioni formali necessarie alla completa comprensione del lavoro di tesi.
- Il **Capitolo 4** presenta l'idea alla base del lavoro di tesi, l'architettura completa del sistema implementato e i limiti teorici e pratici del lavoro svolto. Vengono illustrate in dettaglio le modifiche apportate al meccanismo di campionamento dei token visivi per consentire l'embedding del messaggio segreto cifrato direttamente nel flusso generativo.
- Il **Capitolo 5** espone in modo esaustivo i risultati delle sperimentazioni condotte. Vengono valutate sia la qualità visiva delle immagini generate, attraverso l'utilizzo di metriche consolidate come la Fréchet Inception Distance (FID), sia la capacità steganografica del sistema, analizzando il payload trasferibile e la robustezza contro attacchi di rilevamento.

- Infine, il **Capitolo 6** trae le conclusioni finali del lavoro svolto, riassumendo i contributi principali della ricerca e delineando una serie di possibili sviluppi futuri, mirati al miglioramento incrementale dell'efficienza, della robustezza e della sicurezza complessiva del sistema proposto.

---

## STATO DELL'ARTE

---

### 2.1 METEOR: UN FRAMEWORK DI STEGANOGRAFIA GENERATIVA SU TESTO

#### 2.1.1 *Contesto e motivazioni*

La necessità di una solida comprensione teorica, indispensabile per contestualizzare appieno il presente lavoro di ricerca, si articola attraverso una costellazione di concetti interdipendenti che convergono in un'unica opera fondamentale: [17], nominalmente nota come *Meteor*. Questa indagine, che va oltre una mera disamina della steganografia classica e di quella generativa, introduce primariamente un approccio metodologico e, in secondo luogo, un framework robusto ed efficiente deputato alla *generazione di messaggi testuali contenenti informazioni celate*.

La peculiarità di queste informazioni risiede nella loro intrinseca invisibilità non solo all'occhio umano, ma anche, e soprattutto, alle più sofisticate tecniche di steganalisi basate su divergenza statistica. La ragione di tale elusività risiede nella formalizzazione del concetto di *perfectly secure steganography* nel dominio del linguaggio naturale: il testo generato da *Meteor* non manifesta alcuna deviazione statistica significativa rispetto a un testo prodotto autonomamente dal medesimo modello linguistico di base (il cosiddetto *cover distribution*). Come verrà dettagliato in seguito, *Meteor* si avvale di un modello linguistico che ha raggiunto una notevole notorietà, estendendosi ben oltre gli ambiti accademici tradizionali, configurandosi come uno dei primi Transformer a larga scala a influenzare il dibattito pubblico sulla capacità generativa delle IA. Nello specifico, *Meteor* impiega il modello **GPT-2** (Generative Pre-trained Transformer 2), caratterizzato da un'architettura *decoder-only* addestrata su un corpus massivo di dati testuali (WebText). Tuttavia, l'architettura del framework è stata concepita con una notevole flessibilità, risultando agnostica rispetto al modello linguistico sottostante (*Backbone LLM*). Questa modularità


permette a *Meteor* di beneficiare direttamente dei progressi nello stato dell'arte dei modelli linguistici, poiché l'efficacia della steganografia è intrinsecamente legata alla capacità del modello di approssimare la vera distribuzione del linguaggio umano ( $P_{\text{data}}$ ).

Per una comprensione ancora più profonda, è opportuno esaminare il contesto socio-tecnologico in cui *Meteor* è maturato e le problematiche specifiche che si proponeva di risolvere, con particolare attenzione alla crescente sofisticazione dei sistemi di sorveglianza e censura digitale. In un'epoca in cui la libertà di espressione e la privacy online sono costantemente minacciate da regimi autoritari e da sistemi di filtraggio sempre più avanzati, la necessità di strumenti di comunicazione *copyright-resistant* è diventata più urgente che mai. *Meteor* si inserisce in questo contesto come una risposta innovativa, offrendo un metodo per nascondere informazioni all'interno di testi generati in modo naturale, rendendo estremamente difficile per qualsiasi osservatore esterno rilevare la presenza di un messaggio segreto.

L'essenza di *Meteor* risiede nell'idea innovativa di utilizzare un modello generativo per la creazione di contenuti steganografici, sfruttando la sua capacità di modellare la probabilità condizionata  $P(x_t|x_{<t})$ . In termini pratici, il modello agisce come un sofisticato stimatore di densità: data una sequenza di contesto iniziale (*prompt*), esso fornisce una distribuzione di probabilità dettagliata (solitamente tramite una funzione *softmax* applicata ai *logits*) per tutti i possibili *token* contenuti nel vocabolario  $\mathcal{V}$ . La scelta del *token* da inserire nella sequenza viene effettuata tramite un meccanismo di campionamento che mappa i bit del messaggio segreto in indici del vocabolario, seguendo l'ordinamento indotto dalla distribuzione di probabilità. Questa metodologia trasforma il processo di inferenza in un'operazione di codifica di canale: il testo risultante è statisticamente probabile secondo il modello, ma contiene un messaggio segreto decodificabile univocamente dal destinatario. La decodifica è resa possibile a condizione che il ricevente disponga dello stesso modello linguistico, della medesima sequenza di contesto e di una chiave privata condivisa (*shared secret*), necessaria per inizializzare il generatore di numeri pseudo-casuali o per definire le permutazioni degli indici del vocabolario.

Costruiamo ora uno scenario illustrativo volto a consolidare la comprensione del meccanismo operativo di *Meteor*. Immaginiamo una comunicazione confidenziale tra due entità, Alice (A) e Bob (B), che desiderano scambiarsi informazioni sensibili attraverso un canale pubblico monitorato. L'obiettivo primario è impedire a un osservatore avversario, Eve

(E), di rilevare la presenza stessa della comunicazione (*steganographic undetectability*). Un contesto critico si verifica quando Alice o Bob operano all'interno di infrastrutture soggette a *Deep Packet Inspection* (DPI) o filtraggio governativo stringente. In tali scenari, i messaggi cifrati tramite crittografia standard (come AES o RSA) presentano un'elevata entropia e caratteristiche distintive che li rendono facilmente identificabili come traffico cifrato, risultando facilmente identificabili come traffico non lecito e quindi soggetto a blocco immediato (Figura 1). Un esempio emblematico è il sistema descritto in [26], il "Great Firewall", che impiega euristiche avanzate per discriminare tra traffico legittimo e protocolli di tunneling o cifratura. All'interno di questo quadro ostile, la steganografia generativa supera il limite della crittografia tradizionale: non si limita a proteggere il contenuto, ma nasconde l'esistenza stessa dell'atto comunicativo. Eve, osservando il transito di un testo coerente e stilisticamente appropriato, non ha basi statistiche per etichettare la comunicazione come sospetta<sup>1</sup>.



**Figura 1:** Rappresentazione schematica di una comunicazione tra Alice (A) e Bob (B) in presenza di un osservatore esterno, Eve (E), e di un sistema di filtraggio dei contenuti (Firewall) che analizza la firma statistica dei pacchetti.

Sotto il profilo teorico, la progettazione di *Meteor* ha richiesto la risoluzione di due criticità fondamentali intrinseche alla natura del linguaggio

<sup>1</sup> Nel presente scenario, "segreto" e "privato" sono usati in senso tecnico: una comunicazione è steganograficamente sicura se la divergenza di Kullback-Leibler tra la distribuzione dei messaggi naturali e quella dei messaggi steganografici tende a zero.

naturale.

La prima sfida concerne la definizione di un *sampler steganografico* efficace. L'algoritmo deve mappare il contesto fornito al modello in una distribuzione di probabilità del token successivo che ricalchi quanto più fedelmente possibile quella del linguaggio naturale. Risulta tuttavia evidente che il linguaggio naturale non sottostia a una distribuzione di probabilità assoluta e invariante: si considerino, a titolo esemplificativo, le divergenze linguistiche intercorrenti tra un testo dei primi del Novecento e uno contemporaneo, o tra la prosa scientifica e quella letteraria. *Meteor* affronta tale complessità adottando un modello di generazione testuale come approssimatore dinamico del linguaggio naturale. Tale approccio consente di simulare efficacemente la distribuzione linguistica in molteplici domini, superando il problema dell'assenza di una distribuzione statistica universale che ha storicamente limitato la steganografia classica. È tuttavia opportuno precisare che l'efficacia di *Meteor* è intrinsecamente dipendente dalla capacità del modello linguistico sottostante (il *Backbone LLM*) di approssimare la distribuzione reale. Qualora il modello non riuscisse a catturare le sfumature e le complessità semantiche del linguaggio umano, la steganografia generativa diverrebbe vulnerabile a tecniche di rilevamento avanzate. Cionondimeno, ogni output prodotto da *Meteor* risulta statisticamente indistinguibile da un testo generato autonomamente dal medesimo modello; ciò garantisce una sicurezza steganografica assoluta, a condizione che non sia possibile distinguere tra un testo prodotto dal modello e uno naturale.

La seconda sfida è legata alla variabilità dell'entropia testuale. In segmenti caratterizzati da elevata densità semantica o vincoli sintattici stringenti (bassa entropia), la libertà di selezione del token successivo è pressoché nulla. Ad esempio, data la sequenza "*The largest carnivore of the Cretaceous period was the Tyrannosaurus*", il "token" "*Rex*" presenta una probabilità estremamente elevata. Forzare la codifica di bit in tale posizione selezionando un token alternativo produrrebbe un'anomalia semantica macroscopica, facilmente individuabile da un classificatore neurale. Per ovviare a ciò, *Meteor* introduce una soglia di entropia minima: il sistema analizza la distribuzione di probabilità a ogni passo temporale e determina dinamicamente se la varianza sia sufficiente per ospitare informazione. Se l'entropia è inferiore a un valore critico  $\tau$ , il sistema genera un token senza inserire informazione steganografica. Qualora, invece, l'entropia superi tale soglia, il sistema seleziona i token con probabilità rilevanti, escludendo la coda della distribuzione. Attraverso un meccanismo di partizionamento degli indici basato sulle probabilità relative, viene



campionato il token i cui estremi dell'intervallo di probabilità presentino una corrispondenza tra i bit più significativi e i bit del messaggio da codificare. Nel caso in cui l'intervallo non permetta la codifica di alcun bit (ovvero quando gli estremi non condividono il prefisso binario), *Meteor* adotta una strategia a bitrate variabile, rinunciando all'inserimento di informazione per quel determinato passo. In fase di decodifica, la conoscenza della distribuzione di probabilità e dei relativi indici consente di determinare univocamente se l'informazione sia stata inserita o meno, ponendo recuperare l'intervallo relativo al token selezionato e recuperando i bit più significativi comuni per tutti i valori nell'intervallo. Sebbene tale eventualità sia rara data l'elevata entropia media del linguaggio, questa strategia di codifica adattiva (*adaptive rate*) garantisce che il throughput informativo sia massimizzato esclusivamente dove il linguaggio offre una ridondanza naturale, preservando rigorosamente l'integrità statistica del testo prodotto.

### 2.1.2 Meccanismo Operativo del Protocollo Meteor

Il concetto fondamentale che differenzia Meteor dai metodi tradizionali di steganografia è lo spostamento del paradigma: l'informazione non viene "nascosta" all'interno di un oggetto esistente tramite modifiche (embedding), ma viene utilizzata per **guidare il processo di campionamento** durante la generazione di un nuovo media.

Il funzionamento pratico del protocollo si articola nelle seguenti fasi sequenziali:

1. **Cifratura del Messaggio:** Il messaggio segreto viene cifrato utilizzando una chiave simmetrica condivisa tra mittente e destinatario. Questo passaggio è essenziale per trasformare il messaggio in una stringa di bit computazionalmente indistinguibile dal rumore casuale, garantendo che le scelte di campionamento effettuate dal protocollo non presentino pattern statistici rilevabili.
2. **Accesso alla Distribuzione Condizionata:** Meteor si appoggia a un modello generativo pre-addestrato (originariamente GPT-2 il quale possiede un'architettura basata su Transformers, necessità imprescindibile anche per lo sviluppo di modelli nel dominio visivo, quindi anche nel caso della VQ-GAN utilizzata nella nostra implementazione, che vedremo in seguito). Ad ogni passo temporale  $t$ , il modello riceve il contesto dei token già generati e produce una

**distribuzione di probabilità**  $P$  su tutto il vocabolario dei possibili token successivi.

3. **Campionamento Vincolato:** Invece di campionare casualmente o scegliere il token più probabile, Meteor utilizza i bit del messaggio cifrato come "indice" per selezionare il token dalla distribuzione  $P$ . Lo spazio di probabilità viene partizionato e mappato sulle sequenze di bit in modo che il token scelto sia sempre **statisticamente coerente** con il modello, selezionando il token tra quelli più probabili, eliminando la coda della distribuzione sotto una soglia pre-specificata di probabilità. Poiché la scelta avviene all'interno della distribuzione naturale del modello, l'output steganografico rimane indistinguibile da un output generato classicamente dallo stesso modello.
4. **Generazione Iterativa:** Questo processo avviene in modo autoregressivo. Ogni token generato entra a far parte del nuovo contesto per il passo successivo, continuando fino a quando l'intero media (o la sequenza di token visivi necessari per ricostruire l'immagine tramite il decoder VQ-GAN) non è completo. Il troncamento non è netto dopo la codifica dell'ultimo token, ma può essere definito da un carattere speciale che indica la fine del messaggio, o da un limite di lunghezza predefinito. In questo modo, il testo o l'immagine risultante è completamente naturale e coerente, senza alcuna evidenza della presenza di un messaggio nascosto.
5. **Estrazione e Decodifica:** Il ricevente, possedendo lo stesso modello generativo e la chiave simmetrica, è in grado di ricreare le medesime distribuzioni di probabilità  $P$  per ogni passo del processo. Identificando quali token sono stati effettivamente inclusi nello stego-media ricevuto, il destinatario può risalire ai bit che hanno determinato quelle scelte, ricostruendo il messaggio cifrato e, infine, il segreto originale.

L'efficacia di Meteor risiede nella sua capacità di eliminare le anomalie statistiche che gli strumenti di **steganalisi moderna** solitamente identificano. In questo contesto, il messaggio segreto non è contenuto "nei" dati, ma rappresenta la **ragione deterministica** per cui determinati dati coerenti sono stati generati al posto di altri.

Per comprendere appieno il flusso del protocollo, è utile illustrare uno scenario concreto<sup>2</sup>. Supponiamo che Alice voglia comunicare con il compagno Bob senza che sua madre Eve, esperta di reti di telecomunicazioni e ostile alla loro relazione, lo venga a sapere. Alice ha dimenticato il proprio computer a casa di Bob e deve chiedergli di riportarglielo, ma Eve intercetta ogni comunicazione all'interno della rete domestica. In questo scenario, Alice ha esaurito il traffico dati cellulare e non ha accesso a reti Wi-Fi alternative. Il firewall di casa è stato configurato da Eve per bloccare qualsiasi traffico crittografato end-to-end; i messaggi devono transitare in chiaro per poter superare il gateway. La navigazione esterna è mediata da un proxy che instrada le informazioni tramite un protocollo, ideato dalla stessa Eve, che lascia i contenuti leggibili. Di conseguenza, ogni messaggio inviato o ricevuto da Alice è potenzialmente visibile a sua madre.

In questo contesto, qualsiasi comunicazione cifrata in forma tradizionale verrebbe immediatamente bloccata. Alice e Bob decidono quindi di utilizzare *Meteor*. Alice redige un messaggio segreto: «Mi porteresti il portatile domani per favore, l'ho lasciato sul tavolo di cucina da te.». Utilizzando una chiave simmetrica condivisa (ad esempio la data del loro anniversario), Alice cifra il testo ottenendo una stringa di bit. Il messaggio originale, lungo 87 caratteri in codifica ASCII, corrisponde a 87 byte, ovvero 696 bit. Dopo la cifratura, si ottiene una sequenza di 696 bit che è computazionalmente indistinguibile da una stringa interamente casuale. Poiché l'invio diretto di tale stringa verrebbe intercettato e bloccato da Eve, Alice si affida a *Meteor* per trasformarla.

Eve è abituata a vedere Alice e Bob scambiarsi testi generati da modelli linguistici mentre studiano insieme per l'università. Alice, studentessa di ingegneria informatica, decide di sfruttare questa abitudine: sa che Eve non sospetterà nulla se vedrà transitare nella chat una serie di messaggi relativi alla preparazione dell'esame di Analisi II, scambiandoli per normali interazioni con un LLM. Alice inserisce il messaggio cifrato in *Meteor* e fornisce come contesto iniziale (*prompt*) il testo di un esercizio sullo studio del dominio di una funzione. Il framework genererà un testo che non solo nasconde il messaggio cifrato in modo trasparente, ma risulterà anche semanticamente coerente con il contesto matematico fornito.

---

<sup>2</sup> L'esempio proposto rappresenta una forzatura narrativa volta a evitare i classici scenari di sorveglianza bellica o regimi autoritari. Sebbene la trama possa apparire singolare, ogni passaggio tecnico descritto riflette operazioni realmente attuabili a livello pratico.

L'efficienza di questo processo dipende dalla «precisione» di *Meteor*, ovvero dal numero di bit che possono essere codificati in un singolo token. Questo valore è influenzato dalla dimensione del vocabolario e dalla distribuzione di probabilità dei token. Mentre per modelli come GPT-2 è teoricamente possibile codificare fino a 32 bit per token, in media se ne ottengono circa 15. Tuttavia, in contesti a bassa entropia come un esercizio di analisi, la capacità di codifica può scendere sensibilmente. Supponendo uno scenario cautelativo con una capacità di 5 bit per token (con token mediamente composti da 4 caratteri), per codificare i 696 bit del messaggio Alice dovrà generare un testo di circa 140 token (circa 560 caratteri). Tale lunghezza è perfettamente compatibile con una normale risposta di un assistente virtuale.

Per segnalare la fine della comunicazione, può essere utilizzato un carattere speciale che indichi al destinatario il termine del messaggio, per quanto non sia fondamentale in quanto, in caso di assenza di questo carattere, la decodifica procederà normalmente con l'unica differenza che i token decodificati nella fase finale del messaggio sembreranno casuali.

L'output che Eve osserverà sarà simile al seguente:

---

"Il dominio di una funzione di due variabili e' l'insieme delle coppie  $(x, y) \in \mathbb{R}^2$  per le quali la funzione e' definita. Consideriamo ad esempio  $f(x, y) = \sqrt{1 - x^2 - y^2}$ ; affinche' la radice quadrata sia definita, deve valere  $1 - x^2 - y^2 \geq 0$ , ovvero  $x^2 + y^2 \leq 1$ , che rappresenta il cerchio unitario chiuso nel piano cartesiano. Prendiamo invece  $g(x, y) = \frac{1}{x^2 + y^2 - 1}$ : il denominatore si annulla quando  $x^2 + y^2 = 1$ , quindi il dominio e' tutto  $\mathbb{R}^2$  esclusa la circonferenza di raggio 1. Per  $h(x, y) = \log(x - y)$ , la condizione e'  $x - y > 0$ , ossia il semipiano al di sopra della bisettrice  $y = x$ . In generale, per determinare il dominio di una funzione multivariata, dobbiamo identificare tutte le condizioni che potrebbero rendere l'espressione non definita, come radici di indice pari di argomenti negativi, denominatori nulli o argomenti di logaritmi non positivi. La soluzione e' tipicamente un sottoinsieme di  $\mathbb{R}^2$  o  $\mathbb{R}^3$ , la cui rappresentazione grafica risulta spesso essenziale per visualizzare le regioni di validita' della funzione."

---

**Listato 1:** Esempio di testo generato da *Meteor* contenente un messaggio cifrato. Il messaggio è in formato Markdown, il principale stile di formattazione degli LLM moderni.

In questo testo, i token non sono stati scelti tramite un campionamento casuale (*random sampling*) sulla testa della distribuzione, ma tramite la codifica dei bit del messaggio segreto. Per ogni passo, *Meteor* ha generato la distribuzione di probabilità tramite il modello linguistico, ha rimosso la coda della distribuzione sotto una soglia prefissata e ha ordinato i *logits* ottenuti. Gli indici, distribuiti proporzionalmente alle probabilità dei token in un intervallo da 0 a  $2^p$  (dove  $p$  è la precisione), sono stati usati per selezionare il token i cui bit più significativi corrispondessero ai bit successivi del messaggio cifrato.

Se, ad esempio, i bit da codificare fossero 0101110101... e le distribuzioni di probabilità dei token disponibili coprissero gli intervalli 0001..., 0100..., 0110... e 1010..., *Meteor* selezionerebbe il token associato all'intervallo [0100..., 0110...), codificando i primi due bit (01). Al passaggio successivo, il token selezionato entra a far parte del contesto del modello e i bit codificati vengono rimossi dalla testa del messaggio segreto, procedendo iterativamente fino al completamento o al raggiungimento dei limiti impostati.

Il testo risultante, coerente e naturale, transita sulla rete domestica senza destare sospetti. Bob, ricevendo il messaggio, utilizza lo stesso modello e la medesima chiave per estrarre i bit e decifrare la comunicazione, comprendendo la richiesta di Alice. Grazie a *Meteor*, Alice è riuscita a eludere la sorveglianza di Eve, rendendo la comunicazione indistinguibile da un comune output di un modello linguistico (e magari è riuscita anche ad ottenere la risposta al problema di analisi che stava studiando, ma questo non dipende da *Meteor*).

## 2.2 VQ-GAN: GENERAZIONE DI IMMAGINI AD ALTA RISOLUZIONE

### 2.2.1 Contesto e motivazioni

L'introduzione delle architetture GAN (Generative Adversarial Networks) ha rappresentato una svolta nel campo della generazione di immagini, consentendo la creazione di contenuti visivi di qualità, fino ad una dimensionalità massima (coerente) di 256x256 pixel. Tuttavia, le GAN tradizionali hanno mostrato limitazioni significative nella generazione di immagini ad alta risoluzione, principalmente a causa della difficoltà nel mantenere la coerenza globale dell'immagine. In questo contesto, le VQ-GAN (Vector Quantized Generative Adversarial Networks) sono emerse come una soluzione innovativa, combinando i vantaggi delle GAN, ed in particolare dei layer convoluzionali al suo interno, con un

approccio di quantizzazione vettoriale che consente di generare immagini ad alta risoluzione in modo più efficiente in quanto gli indici derivanti dal processo di quantizzazione possono essere trattati come token, analogamente a quanto avviene nei modelli linguistici, e quindi essere processati da un transformer, come GPT-2, il quale permette di mantenere consistenza nelle relazioni a lunga distanza, superando così le limitazioni delle GAN tradizionali introducendo consistenza non solo a livello sintattico, capacità derivante dall'utilizzo di layer convolutivi, ma anche a livello semantico. Le VQ-GAN, grazie alla loro capacità di apprendere rappresentazioni discrete e compatte delle immagini, hanno dimostrato di essere particolarmente efficaci nella generazione di contenuti visivi complessi e dettagliati, rendendole, per un periodo, la scelta preferita dalle aziende che producevano modelli generativi di immagini ad alta risoluzione. Il successo dei Diffusion Transformer, che hanno superato le VQ-GAN in termini di qualità e coerenza delle immagini generate, ha portato a un declino dell'utilizzo di queste ultime. Tuttavia, le VQ-GAN rimangono una pietra miliare nello sviluppo della generazione di immagini ad alta risoluzione e continuano a essere oggetto di studio e applicazione in vari contesti, inclusa la steganografia generativa.

### 2.3 LAVORI CORRELATI

La letteratura sulla steganografia generativa applicata al dominio visivo ha seguito un'evoluzione che è coincisa con l'avanzamento delle tecniche di generazione multimediale, principalmente open-weights, passando attraverso varie fasi. Fintanto che i modelli generativi presentavano limitazioni prestazionali nella produzione di immagini sintatticamente e semanticamente coerenti, la ricerca si è concentrata principalmente su tecniche di embedding in immagini reali, con l'obiettivo di minimizzare le anomalie statistiche e percettive introdotte, perfezionando tecniche quali LSB (Least Significant Bit) e DCT (Discrete Cosine Transform). Queste si sono tuttavia rivelate vulnerabili a tecniche di steganalisi, nate e sviluppate proprio allo scopo di individuare, con una certa probabilità, la presenza di un messaggio nascosto all'interno di un contenuto multimediale.

Con la crescita architetturale e l'aumento della capacità parametrica dei modelli generativi, è emersa la possibilità che questi contenuti multimediali generati potessero diventare oggetto di interesse e che, in modo del tutto naturale, le persone iniziassero a scambiarsi contenuti multimediali generati per interesse personale. Ciò ha permesso l'identificazione di un

nuovo vettore steganografico, ovvero le immagini generate, eliminando la necessità di immagini reali o pre-esistenti per l'embedding delle informazioni. Da questa analisi è emersa la possibilità di adottare un approccio *coverless*, in cui l'immagine di copertura non preesiste ma viene generata contestualmente all'incorporazione del messaggio segreto.

Le prime reti sviluppate per la generazione di contenuti multimediali di qualità crescente, in particolare immagini  $256 \times 256$  pixel, sono state le GAN (Generative Adversarial Networks), ovvero reti neurali caratterizzate da un'elevata densità di strati convolutivi. Nella prima fase di adozione di queste architetture si è osservata un'inconsistenza nelle immagini generate, che presentavano anomalie sia a livello sintattico che semantico. Con il passaggio ad architetture più complesse, come VQ-GAN, l'idea di utilizzare le immagini generate come vettore steganografico è stata effettivamente esplorata. L'approccio alla steganografia su contenuti multimediali non è stato inizialmente differente rispetto a quello precedente, privilegiando tecniche già note come LSB e DCT. Un secondo approccio, meno conservativo, simile a quello utilizzato nel framework sviluppato nel presente lavoro, ha invece evitato di impiegare un'immagine reale come *cover object*, utilizzandola piuttosto come base contestuale per la generazione di un'immagine ad hoc, in cui il messaggio segreto viene codificato direttamente durante il processo generativo. In questo modo, è stato possibile superare le limitazioni legate alla necessità di minimizzare le anomalie introdotte dall'embedding, poiché l'immagine generata è stata progettata fin dall'inizio per incorporare il messaggio segreto in modo naturale e coerente. Diverse architetture in questa prima fase erano infatti concepite per trasformare un contesto derivante da un'immagine reale in un'immagine generata che fosse o modificata in qualche aspetto (con il conseguente aumento del rischio di errori sintattici o semantici) oppure "ricalcata", ovvero che copiasse solo le feature più significative, come per esempio la forma dell'immagine, ovvero le regioni in cui il contrasto era maggiore (i contorni degli oggetti). Questa fase ha visto maturare proposte differenti sulla falsariga di questa idea. L'idea di base, ovvero quella di utilizzare un contenuto multimediale esistente, non è scomparsa con il declino delle architetture GAN, ma è rimasta anche con l'avvento di architetture più performanti come i Diffusion Transformer.

La maggior parte di queste tecniche non ha mai raggiunto quello che potremmo definire un framework steganografico formalmente sicuro, poiché non è mai stato possibile garantire una decodifica priva di errori. Questo è dovuto al fatto che le tecniche non si basavano sulla costruzione omnicomprensiva dell'immagine, bensì sulla modifica di alcune sezioni,

talvolta marginali, talvolta limitate a dettagli stilistici (quindi meno evidenti a un rivelatore umano o artificiale), come per esempio una texture o un rumore di fondo.

Queste motivazioni ci hanno spinto a esplorare l'utilizzo di un framework formalmente sicuro come *Meteor* in un contesto di generazione multimediale, per verificare se i concetti alla base di questo framework potessero risolvere, almeno parzialmente, le criticità emerse nell'implementazione di un framework multimediale formalmente sicuro.



---

## DEFINIZIONI E TERMINOLOGIA

---

Nel seguito sono presentati un insieme di termini e definizioni fondamentali per la comprensione dei concetti chiave trattati nella tesi. I termini sono organizzati per aree tematiche omogenee, procedendo dai fondamenti della comunicazione sicura fino agli aspetti più specialistici della generazione steganografica. Questo lessico tecnico costituisce il vocabolario essenziale per navigare efficacemente all'interno del discorso sulla steganografia generativa, sui modelli linguistici, sulle architetture di reti neurali e sui generatori di immagini.

### 3.1 CONCETTI FONDAZIONALI DELLA COMUNICAZIONE

**Plaintext:** informazione nella sua forma originaria e integralmente leggibile, antecedente a qualsiasi trasformazione crittografica o steganografica. Nel contesto della presente trattazione, il plaintext costituisce il dato in chiaro che si intende proteggere.

**Ciphertext:** risultato dell'applicazione di un algoritmo di cifratura a un plaintext. Tale rappresentazione, incomprensibile in assenza della corrispondente chiave di decifrazione, costituisce il prodotto finale del processo crittografico.

**Coverobject:** oggetto multimediale originale, nella sua forma inalterata, che funge da contenitore all'interno del quale si intende occultare un messaggio segreto.

**Stegoobject:** oggetto risultante dall'incorporazione del messaggio segreto all'interno del coverobject. La proprietà fondamentale che tale artefatto deve soddisfare è l'indistinguibilità percettiva e statistica dal coverobject originale. Nel caso di *Meteor* o delle VQ-GAN, il termine si riferisce all'oggetto **generato** che contiene l'informazione segreta codificata, che non è in senso stretto un "oggetto modificato" ma un "oggetto creato" ad hoc. In questo contesto, il termine "stegoobject" è usato in

modo estensivo per indicare qualsiasi output generato che contenga un messaggio segreto, indipendentemente dal fatto che sia stato ottenuto tramite embedding o generazione ex novo.

**Payload:** quantità di informazione segreta, espressa in bit, che può essere occultata all'interno di un coverobject senza comprometterne l'integrità statistica e percettiva.

### 3.2 DISCIPLINE DELLA COMUNICAZIONE SICURA

**Crittografia:** disciplina formale che si occupa di rendere non intelligibile un messaggio ad attori non autorizzati mediante l'applicazione di metodi di cifratura. La crittografia costituisce la tecnica preminente per garantire la confidenzialità dei dati nei sistemi informatici contemporanei. Tale disciplina si fonda su principi matematici e algoritmi atti a trasformare l'informazione in una forma cifrata, decifrabile esclusivamente da chi possiede la chiave corretta. Pur costituendo il fondamento dei sistemi comunicativi moderni, la crittografia è potenzialmente vulnerabile ad attacchi di forza bruta, a exploit basati su vulnerabilità specifiche degli algoritmi, a compromissioni delle chiavi e, in prospettiva, ad algoritmi di decriptazione quantistica. Quando implementata correttamente, la crittografia fornisce un livello di sicurezza elevato, rendendo computazionalmente proibitivo l'accesso non autorizzato ai dati [7].

**Cifratura simmetrica:** paradigma crittografico in cui il medesimo segreto condiviso viene impiegato tanto per la cifratura quanto per la decifrazione del messaggio. Tale metodologia, generalmente caratterizzata da una maggiore efficienza computazionale rispetto alla cifratura asimmetrica, richiede che la chiave sia trasmessa in modo sicuro tra le parti coinvolte.

**Steganografia:** disciplina che si occupa di occultare l'esistenza stessa di un messaggio all'interno di un oggetto multimediale, rendendolo impercettibile a osservatori non autorizzati. La steganografia si configura come tecnica complementare alla crittografia: mentre quest'ultima protegge il contenuto informativo, la steganografia tutela la riservatezza dell'atto comunicativo. Storicamente impiegata per finalità di spionaggio e comunicazione clandestina, la steganografia ha trovato nuove applicazioni nell'era digitale, quali la protezione dei diritti d'autore, la comunicazione sicura e la salvaguardia della privacy in rete [22]. Le modalità di implementazione includono l'inserimento di dati occulti in

immagini, tracce audio o flussi video, nonché l'impiego di tecniche di codifica testuale. La steganografia è tuttavia vulnerabile a tecniche di rilevamento avanzate (steganalisi) che analizzano le proprietà statistiche degli oggetti multimediali per identificare anomalie indicative della presenza di dati nascosti.

**Steganalisi:** disciplina deputata al rilevamento di messaggi occulti all'interno di oggetti multimediali, avvalendosi di metodologie di analisi statistica e di apprendimento automatico. La steganalisi costituisce il corrispettivo avversario della steganografia, concentrandosi sull'individuazione dell'esistenza stessa del messaggio celato piuttosto che sulla sua protezione. Con l'avvento delle tecnologie digitali, la steganalisi ha raggiunto livelli di sofisticazione notevoli, impiegando algoritmi avanzati per l'esame delle caratteristiche statistiche degli oggetti multimediali [10].

### 3.3 FONDAMENTI DI MODELLAZIONE LINGUISTICA

**Modelli linguistici:** classe di modelli di intelligenza artificiale progettati per comprendere e generare testo in linguaggio naturale. Tali modelli vengono addestrati su ingenti quantità di dati testuali e impiegano tecniche di apprendimento automatico per apprendere le regolarità grammaticali, il significato delle parole e le relazioni sintattico-semantiche tra le frasi. I modelli linguistici trovano applicazione in sistemi quali chatbot, piattaforme di traduzione automatica, generatori di testo e analizzatori del sentiment. Essi possono presentare vulnerabilità riconducibili a bias nei dati di addestramento e a limitazioni nella comprensione del contesto.

**Modelli di linguaggio di grandi dimensioni (LLM):** sottocategoria di modelli linguistici caratterizzata da un numero di parametri elevato, che consente di apprendere rappresentazioni più complesse del linguaggio naturale e di generare testo con maggiore coerenza e naturalezza. Gli LLM vengono addestrati su corpora testuali di dimensioni massive e si avvalgono di architetture avanzate, quali i Transformer, per catturare le dipendenze a lungo termine tra le unità linguistiche.

**Modelli generativi:** classe di modelli di intelligenza artificiale atti a generare nuovi dati che presentano caratteristiche analoghe a quelli impiegati in fase di addestramento. Attraverso tecniche di apprendimento automatico, tali modelli apprendono la distribuzione sottostante ai dati di training e producono nuovi campioni che seguono la medesima

distribuzione. I modelli generativi trovano impiego in numerosi ambiti, inclusi la generazione testuale, la sintesi di immagini, la composizione musicale e la sintesi vocale.

### 3.4 COMPONENTI DEI MODELLI LINGUISTICI

**Token:** unità testuale elementare impiegata nei modelli linguistici, corrispondente a una parola, un carattere o una sottoporzione di parola. I token costituiscono l'unità fondamentale su cui operano i modelli linguistici, rappresentando le entità minime che il modello deve elaborare e generare. La tokenizzazione – il processo di suddivisione del testo in token – può essere effettuata secondo diverse modalità, quali la segmentazione per parole, per caratteri o per sottoparole (ad esempio mediante algoritmi *subword* come Byte Pair Encoding).

**Vocabolario:** insieme dei token che un modello linguistico è in grado di processare e generare. Il vocabolario viene definito durante la fase di addestramento e la sua dimensione può variare in funzione del modello e dell'applicazione. Un vocabolario più esteso consente al modello di coprire una gamma più ampia di espressioni linguistiche, ma comporta un aumento della complessità computazionale.

**Logits:** valori numerici prodotti dall'ultimo strato di un modello generativo prima dell'applicazione della funzione di attivazione (tipicamente la softmax) per ottenere una distribuzione di probabilità sui token successivi. I logits rappresentano le preferenze del modello per ciascun token del vocabolario, dove valori più elevati indicano una maggiore propensione alla selezione.

**Softmax:** funzione di attivazione impiegata nei modelli linguistici per trasformare il vettore dei logits in una distribuzione di probabilità sull'insieme dei token del vocabolario. Formalmente,  $\text{softmax}(x_i) = e^{x_i} / \sum_j e^{x_j}$ , dove  $x_i$  rappresenta il logit corrispondente al token  $i$ -esimo e la somma al denominatore è estesa all'intero vocabolario.

### 3.5 MECCANISMI DI GENERAZIONE E CONTROLLO

**Prompt:** sequenza testuale iniziale fornita in input a un modello linguistico per orientare e condizionare la generazione del testo successivo, definendo il contesto semantico e tematico dell'output prodotto.

**Contesto:** unione dei token del prompt e dei token generati fino a un dato punto temporale, che costituisce l'input su cui il modello linguistico basa la generazione del token successivo. Il contesto è dinamico e si evolve iterativamente con l'aggiunta di nuovi token, influenzando le distribuzioni di probabilità generate dal modello a ogni passo.

**Finestra di contesto:** limite massimo di token che un modello può considerare come input per la generazione del token successivo. La dimensione della finestra di contesto influisce sulla capacità del modello di mantenere coerenza e riferimenti a lungo termine all'interno del testo generato.

**Entropia:** nel contesto attuale, misura della variabilità o incertezza associata alla distribuzione di probabilità dei token successivi generata da un modello linguistico. Un'alta entropia indica una distribuzione più uniforme, con molte opzioni possibili per il token successivo, mentre una bassa entropia suggerisce una distribuzione concentrata su pochi token altamente probabili. L'entropia è un fattore cruciale nella steganografia generativa, poiché determina la capacità del sistema di codificare informazione senza compromettere la naturalezza del testo prodotto.

**Campionamento:** processo di selezione di un token successivo a partire da una distribuzione di probabilità generata da un modello. Le modalità di campionamento includono il campionamento casuale (*random sampling*), la selezione deterministica del token più probabile (*greedy decoding*), il campionamento casuale solo sui k token più probabili (*top-k sampling*), il campionamento casuale solo sui token con probabilità sopra una certa soglia (*top-p sampling* o *nucleus sampling*) e il campionamento vincolato, come nel caso di *Meteor*, in cui la scelta del token è determinata dai bit del messaggio segreto.

### 3.6 ARCHITETTURE DI RETI NEURALI

**Transformer:** architettura di rete neurale basata sul meccanismo di attenzione (*self-attention*), ampiamente adottata nei modelli linguistici di grandi dimensioni per la capacità di catturare relazioni a lungo termine tra gli elementi di una sequenza, superando le limitazioni delle architetture ricorrenti nella modellazione di dipendenze distanti.

**Convolutional layer:** strato che applica operazioni di convoluzione per estrarre caratteristiche locali dai dati in ingresso, comunemente impiegato nelle reti neurali convoluzionali (CNN) per l'elaborazione di segnali strutturati su griglia, quali immagini e volumi multidimensionali.

**Recurrent layer:** strato che introduce connessioni ricorrenti per mantenere e propagare informazioni sullo stato precedente della sequenza, tipicamente utilizzato nelle reti neurali ricorrenti (RNN) per l'elaborazione di dati sequenziali, quali testo, serie temporali e segnali audio.

**Fully connected layer:** strato in cui ogni neurone è connesso a tutti i neuroni dello strato precedente, impiegato principalmente per la classificazione o la regressione dopo l'estrazione di caratteristiche da parte di strati convoluzionali o ricorrenti.

### 3.7 CONCETTI FONDAMENTALI DELLA RAPPRESENTAZIONE VISIVA

**Patch:** porzione di un'immagine, tipicamente di dimensioni fisse, che viene elaborata come unità discreta in modelli di generazione visuale. I patch consentono di suddividere un'immagine in segmenti più gestibili, facilitando l'estrazione di caratteristiche locali e la generazione di contenuti visivi coerenti.

**Spazio latente:** rappresentazione astratta e compressa dei dati in ingresso, appresa da un modello generativo durante la fase di addestramento. Lo spazio latente consente al modello di catturare le caratteristiche essenziali dei dati, facilitando la generazione di nuovi campioni che condividono le stesse proprietà statistiche e semantiche degli esempi di training. Per spazio latente si intende un dominio di rappresentazione in cui i dati originali vengono mappati sulla base delle feature, consentendo al modello di manipolare e generare nuovi campioni attraverso operazioni su queste rappresentazioni astratte. Si utilizza la distanza euclidea o altre metriche di similarità per misurare la vicinanza tra punti nello spazio latente, che riflette la *somiglianza semantica o visiva* tra i dati.

**Semantica di un'immagine:** insieme di significati, concetti e relazioni rappresentati visivamente in un'immagine. La semantica di un'immagine comprende elementi quali oggetti, scene, azioni e contesti che possono essere interpretati da un osservatore umano o da un modello di intelligenza artificiale. La comprensione della semantica di un'immagine è fondamentale per applicazioni come il riconoscimento delle immagini, la generazione di descrizioni testuali e la manipolazione visiva.

**Sintassi di un'immagine:** insieme di regole e strutture che governano l'organizzazione visiva degli elementi all'interno di un'immagine. La sintassi di un'immagine riguarda aspetti quali la composizione, la disposizione spaziale, la prospettiva e le relazioni formali tra gli oggetti rappresentati. La sintassi contribuisce alla percezione estetica e alla

comprensione visiva, influenzando il modo in cui un'immagine viene interpretata e apprezzata.

### 3.8 ARCHITETTURE PER LA GENERAZIONE VISUALE

**Generative Adversarial Network (GAN):** architettura di rete neurale composta da due componenti distinti – un generatore e un discriminatore – che competono tra loro durante la fase di addestramento. Il generatore tenta di produrre dati sintetici indistinguibili da quelli reali, mentre il discriminatore si adopera per discriminare tra campioni autentici e campioni generati. Questo processo di apprendimento avversario conduce a un miglioramento progressivo della qualità dei dati sintetici prodotti.

**Vector Quantized-Generative Adversarial Network (VQ-GAN):** architettura di rete neurale che integra i principi dei GAN con tecniche di quantizzazione vettoriale, impiegando un codebook discreto per rappresentare le caratteristiche latenti dei dati in ingresso. La VQ-GAN è progettata per migliorare la qualità e la stabilità del processo generativo, riducendo al contempo la complessità computazionale mediante la discretizzazione dello spazio latente [20].

**Codebook:** insieme strutturato di vettori latenti appresi durante l'addestramento di un modello basato su quantizzazione vettoriale, come la VQ-GAN. Ciascun vettore del codebook costituisce un elemento atomico del dizionario di rappresentazioni discrete mediante il quale i dati originali vengono codificati e successivamente ricostruiti.

**Quantizzazione:** processo di discretizzazione di uno spazio di rappresentazione continuo (o discreto ma di dimensione eccessivamente elevata) in un insieme finito di valori atomici detti *token*. Tale procedura viene impiegata in architetture come la VQ-GAN per ridurre la complessità del modello e migliorare la stabilità del processo di addestramento, trasformando lo spazio latente continuo in un codebook finito di vettori discreti.

### 3.9 MISURE E GARANZIE NEI SISTEMI STEGANOGRAFICI

**Bitrate variabile:** strategia di codifica in cui la quantità di informazione incorporata in ciascun token può variare dinamicamente in funzione delle caratteristiche del contesto e della distribuzione di probabilità dei token successivi. In contesti a bassa entropia, il sistema può astenersi

dalla codifica di informazione, mentre in scenari ad alta entropia può codificare un numero maggiore di bit per token, massimizzando il throughput informativo senza compromettere la naturalezza statistica del testo generato.

**Throughput informativo:** quantità di informazione segreta, misurata in bit, che può essere codificata e trasmessa attraverso un canale di comunicazione, quale un testo generato da un modello linguistico. Il throughput informativo è determinato da molteplici fattori, tra cui la capacità di codifica del modello sottostante, la distribuzione di probabilità dei token e la strategia di codifica adottata.

**Anomalia semantica:** incoerenza o incongruenza nel significato di un testo generato, riconducibile a selezioni di token non naturali o a errori nel processo generativo. Le anomalie semantiche costituiscono indicatori potenzialmente rivelatori per strumenti di steganalisi, in quanto segnalano una deviazione dal comportamento generativo naturale.

**Soglia di entropia minima:** valore critico dell'entropia al di sotto del quale un sistema di steganografia generativa, quale *Meteor*, si astiene dalla codifica di informazione segreta. Tale soglia garantisce che l'inserimento di informazioni occulte avvenga esclusivamente in contesti in cui la distribuzione di probabilità dei token successivi presenta una varianza sufficiente, prevenendo la generazione di anomalie semantiche.

**Soglia di probabilità:** valore prefissato impiegato per troncare la distribuzione di probabilità dei token successivi prodotta da un modello linguistico, eliminando i token la cui probabilità risulta inferiore a tale soglia. Questo meccanismo, noto come troncamento della coda (*tail truncation*), circoscrive le scelte ai token maggiormente probabili, migliorando la coerenza e la naturalezza del testo generato.

**Troncamento della coda:** tecnica impiegata nei modelli linguistici per limitare l'insieme dei token candidati alla selezione a quelli la cui probabilità supera una soglia prefissata. Tale procedura migliora la coerenza e la naturalezza del testo generato, eliminando i token meno probabili che potrebbero introdurre anomalie semantiche o statistiche. Questa tecnica riveste particolare rilevanza in sistemi di steganografia generativa, come *Meteor*, in quanto contribuisce a garantire che il testo prodotto rimanga statisticamente indistinguibile da un testo naturale.

**Indistinguibilità statistica:** proprietà di un testo generato da un modello linguistico, quale *Meteor*, per cui le sue caratteristiche statistiche risultano indistinguibili da quelle di un testo naturale non steganografico. Tale



proprietà è fondamentale per impedire a strumenti di steganalisi di rilevare la presenza di informazioni occulte basandosi su anomalie statistiche.

**Indistinguibilità percettiva:** proprietà di un testo generato da un modello linguistico, quale *Meteor*, per cui il suo significato e la sua coerenza risultano indistinguibili da quelli di un testo naturale non steganografico. Tale proprietà contribuisce a garantire che il testo prodotto non susciti sospetti basati su anomalie semantiche.

**Non-determinismo:** caratteristica di un sistema di generazione per cui l'output prodotto non è deterministico ma dipende da fattori probabilistici, tra cui la distribuzione di probabilità dei token successivi e la strategia di codifica steganografica adottata. Il non-determinismo contribuisce a garantire l'indistinguibilità statistica e percettiva del messaggio generato. Nel sistema implementato in questa tesi, il non-determinismo ha tuttavia rappresentato una criticità: l'architettura VQ-GAN impiega un codificatore (*Encoder*) e un decodificatore (*Decoder*) che, essendo funzioni statistiche apprese e non inversi esatti, introducono una componente d'errore nel processo di ricostruzione. Questa mancata biettività ha prodotto inconsistenze tra la codifica e la decodifica di alcune patch dell'immagine.



---

## BIBLIOGRAFIA

---

- [1] European Pirate Party. *Chat control 2.0: the sequel nobody asked for*. URL: <https://europeanpirates.eu/chatcontrol-the-sequel-nobody-asked-for/>.
- [2] Gabriel Kaptchuk et al. *Meteor. Cryptographically secure steganography for realistic distributions*. URL: <https://meteorfrom.space/> (visitato il giorno 10/07/2025).
- [3] Adrian Shahbaz. *The rise of digital authoritarianism*. URL: <https://freedomhouse.org/report/freedom-net/2018/rise-digital-authoritarianism>.
- [4] Matteo Suanno. «Cosa significa che Starlink non è più accessibile all'esercito russo in Ucraina». In: (6 feb. 2026). URL: <https://www.wired.it/article/cosa-sappiamo-blocco-starlink-militari-ucraina/>.
- [5] Dave Bergmann e Cole Stryker. *Diffusion models*. 17 Apr. 2025. URL: <https://www.ibm.com/think/topics/diffusion-models> (visitato il giorno 10/07/2025).
- [6] Ari Ibrahim Hamid e Wafaa Mustafa Abdualloh. «StyleGAN2-STEGO: Secure coverless image steganography via latent space encoding». In: *East Journal of Computer Science* 1.4 (30 ago. 2025). DOI: [10.63496/ejcs.vol1.iss4.188](https://doi.org/10.63496/ejcs.vol1.iss4.188). URL: <https://doi.org/10.63496/ejcs.vol1.iss4.188>.
- [7] Corey Neskey. *Are Your Passwords in the Green?* Hive Systems. 2025. URL: <https://www.hivesystems.com/blog/are-your-passwords-in-the-green> (cit. a p. 24).
- [8] Wisdom Sablah. *WhatsApp Banned Countries List & How to Bypass the Ban 2026*. 13 Nov. 2025. URL: <https://www.cloudwards.net/countries-where-whatsapp-is-banned/>.
- [9] Yuhua Xu et al. «Approximate Gaussian Mapping for Generative Image Steganography». In: *arXiv preprint arXiv:2510.07219* (2025).

- [10] Richard Apau et al. «Image steganography techniques for resisting statistical steganalysis attacks: A systematic literature review». In: *PLOS ONE* 19.9 (set. 2024), pp. 1–47. doi: [10.1371/journal.pone.0308807](https://doi.org/10.1371/journal.pone.0308807). URL: <https://doi.org/10.1371/journal.pone.0308807> (cit. a p. 25).
- [11] Li Li et al. «Image Steganography and Style Transformation Based on Generative Adversarial Network». In: *Mathematics* 12.4 (2024). ISSN: 2227-7390. DOI: [10.3390/math12040615](https://doi.org/10.3390/math12040615). URL: <https://www.mdpi.com/2227-7390/12/4/615>.
- [12] Simone Scardapane. *Alice's Adventures in a Differentiable Wonderland – Volume I, A Tour of the Land*. 26 Apr. 2024. URL: <https://arxiv.org/abs/2404.17625>.
- [13] Giulia Bertazzini. «An overview of Diffusion Models in Multimedia Forensics: Generating and Detecting Synthetic Images». 27 Ott. 2023.
- [14] Kemal Erdem. *Step by step visual introduction to diffusion models*. Nov. 2023. URL: <https://erdem.pl/2023/11/step-by-step-visual-introduction-to-diffusion-models> (visitato il giorno 10/07/2025).
- [15] Daniel Bourke. *Learn PyTorch for deep learning in a day. Literally*. 24 Lug. 2022. URL: [https://www.youtube.com/watch?v=Z\\_ikDlimN6A](https://www.youtube.com/watch?v=Z_ikDlimN6A).
- [16] Shuyang Gu et al. «Vector Quantized Diffusion Model for Text-to-Image Synthesis». In: *CoRR* abs/2111.14822 (2021). arXiv: [2111.14822](https://arxiv.org/abs/2111.14822). URL: <https://arxiv.org/abs/2111.14822>.
- [17] Gabriel Kaptchuk et al. *Meteor: Cryptographically Secure Steganography for Realistic Distributions*. Cryptology ePrint Archive, Paper 2021/686. 2021. URL: <https://eprint.iacr.org/2021/686> (cit. a p. 11).
- [18] Nandhini Subramanian et al. «Image Steganography: A Review of the Recent Advances». In: *IEEE Access* 9 (2021), pp. 23409–23423. DOI: [10.1109/ACCESS.2021.3053998](https://doi.org/10.1109/ACCESS.2021.3053998).
- [19] Lilian Weng. *What are Diffusion Models?* 11 Lug. 2021. URL: <https://lilianweng.github.io/posts/2021-07-11-diffusion-models/>.

- [20] Patrick Esser, Robin Rombach e Björn Ommer. «Taming Transformers for High-Resolution Image Synthesis». In: *CoRR* abs/2012.09841 (2020). arXiv: [2012.09841](https://arxiv.org/abs/2012.09841). URL: <https://arxiv.org/abs/2012.09841> (cit. a p. 29).
- [21] Jia Liu et al. «Recent Advances of Image Steganography With Generative Adversarial Networks». In: *IEEE Access* 8 (2020), pp. 60575–60597. DOI: [10.1109/ACCESS.2020.2983175](https://doi.org/10.1109/ACCESS.2020.2983175).
- [22] Gianmarco Turchetta. «Applicazioni blockchain in sistemi di Telemedicina: condivisione e accesso sicuro ai dati sanitari». Tesi di Laurea Magistrale in Ingegneria Biomedica. Politecnico di Torino, 2020. URL: <https://webthesis.biblio.polito.it/17016/> (cit. a p. 24).
- [23] Zhuo Zhang et al. «Generative Steganography by Sampling». In: *IEEE Access* 7 (2019), pp. 118586–118597. DOI: [10.1109/ACCESS.2019.2920313](https://doi.org/10.1109/ACCESS.2019.2920313).
- [24] Donghui Hu et al. «A Novel Image Steganography Method via Deep Convolutional Generative Adversarial Networks». In: *IEEE Access* 6 (2018), pp. 38303–38314. DOI: [10.1109/ACCESS.2018.2852771](https://doi.org/10.1109/ACCESS.2018.2852771).
- [25] Kate Conger. *WhatsApp blocked in Brazil again*. 19 Lug. 2016. URL: <https://techcrunch.com/2016/07/19/whatsapp-blocked-in-brazil-again/>.
- [26] Roya Ensafi et al. «Examining How the Great Firewall Discovers Hidden Circumvention Servers». In: *Proceedings of the 2015 Internet Measurement Conference*. IMC '15. Tokyo, Japan: Association for Computing Machinery, 2015, pp. 445–458. ISBN: 9781450338486. DOI: [10.1145/2815675.2815690](https://doi.org/10.1145/2815675.2815690). URL: <https://doi.org/10.1145/2815675.2815690> (cit. a p. 13).