



UNIVERSITÀ  
DEGLI STUDI  
FIRENZE

Scuola di Scienze Matematiche, Fisiche e Naturali  
Corso di Laurea in Informatica

Tesi di Laurea

STEGANOGRAFIA GENERATIVA SU  
IMMAGINI:  
ADATTAMENTO DEL PROTOCOLLO METEOR  
TRAMITE L'ARCHITETTURA VQ-GAN

GENERATIVE IMAGE STEGANOGRAPHY:  
ADAPTING THE METEOR PROTOCOL TO THE  
VQ-GAN ARCHITECTURE

MATTEO DICIOTTI

Relatore: Prof. *Daniele Baracchi*

Correlatrice: PhD *Giulia Bertazzini*

Correlatore: Prof. *Daniele Castellana*

Anno Accademico 2024-2025

Matteo Diciotti: *Steganografia generativa su immagini:*  
*adattamento del protocollo Meteor tramite l'architettura VQ-GAN*, Corso di  
Laurea in Informatica, © Anno Accademico 2024-2025

---

## INDICE

---

|                                                                                                         |    |
|---------------------------------------------------------------------------------------------------------|----|
| Elenco delle figure                                                                                     | 3  |
| 1 Introduzione                                                                                          | 7  |
| 2 Stato dell'arte                                                                                       | 11 |
| 2.1 Meteor: un framework di steganografia generativa per il testo                                       | 11 |
| 2.2 VQ-GAN: un'architettura generativa a base transformer<br>per immagini ad alta risoluzione . . . . . | 14 |
| Bibliografia                                                                                            | 15 |



---

## ELENCO DELLE FIGURE

---

|          |                                                       |    |
|----------|-------------------------------------------------------|----|
| Figura 1 | Alice e Bob attraversano il firewall di Eve . . . . . | 13 |
|----------|-------------------------------------------------------|----|



*"Questo è bello!"*  
*"Eh, nella sua semplicità.."*  
*"Questo è iper-realista."*  
*"E se me lo concedi monocromatico."*  
*"L'artista è Meteor."*  
*"Meteor, già sentito!"*  
*— Aldo, Giovanni e Giacomo*





---

## INTRODUZIONE

---

L'esigenza intrinseca e crescente di garantire comunicazioni che siano contemporaneamente riservate, autentiche e integre rappresenta un pilastro fondamentale su cui si erge l'architettura stessa del mondo digitale contemporaneo. La sicurezza delle informazioni, in passato, è stata prevalentemente affidata a robuste tecniche crittografiche e a protocolli standard ben consolidati, quali il Transport Layer Security (TLS) e il suo predecessore Secure Sockets Layer (SSL). Questi sistemi sono stati meticolosamente progettati per rendere il contenuto effettivo dei messaggi inaccessibile a qualsiasi entità esterna non in possesso delle chiavi di decifratura appropriate; nel contesto di TLS, ciò si traduce tipicamente nell'esclusione di chiunque non partecipi al processo di negoziazione della connessione (l'handshake).

Tuttavia, l'escalation senza precedenti delle misure di sorveglianza di massa su scala globale e la proliferazione di meccanismi di censura sempre più capillari e sofisticati hanno messo a nudo una vulnerabilità critica, intrinseca e finora difficile da eradicare alla crittografia moderna: la sua stessa visibilità. Sebbene la crittografia riesca efficacemente a mantenere segreto il contenuto dei dati trasmessi, l'elevata entropia e le caratteristiche distintive del traffico cifrato lo rendono facilmente identificabile e distinguibile dalle comunicazioni in chiaro. Questo stato di cose consente a regimi autoritari, a entità statali o a sofisticati sistemi di filtraggio di rete (come i firewall avanzati) di individuare, bloccare o degradare selettivamente le comunicazioni protette, compromettendo così l'effettivo scambio di informazioni sensibili in contesti operativi ostili o sorvegliati.

Di fronte a tali sfide, specialmente in scenari caratterizzati da censura estrema o da ambienti di comunicazione altamente avversari, emerge in modo prepotente la necessità di esplorare e impiegare metodologie steganografiche. La steganografia, come disciplina, si dedica all'arte e alla scienza dell'occultamento di informazioni segrete all'interno di oggetti

di copertura (cover objects) che, a un'osservazione superficiale, appaiono del tutto innocui e non sospetti. Questi oggetti di copertura possono assumere svariate forme, tra cui testi, immagini, file audio o video. A differenza della crittografia, il cui successo e la cui sicurezza dipendono in larga misura dalla complessità matematica o computazionale necessaria per decifrare il messaggio cifrato, la sicurezza in ambito steganografico poggia su un principio radicalmente diverso: l'indistinguibilità statistica. L'obiettivo primario è fare in modo che un osservatore esterno non sia minimamente in grado di discriminare tra un oggetto che contiene un messaggio segreto (denominato stego-object) e un oggetto analogo che ne è privo.

Le metodologie steganografiche classiche, quali ad esempio la manipolazione dei bit meno significativi (Least Significant Bit - LSB) nelle immagini digitali, si sono progressivamente rivelate vulnerabili agli attacchi di crittoanalisi statistica sempre più avanzati e raffinati. Per superare queste limitazioni intrinseche e garantire un livello di sicurezza che sia non solo robusto ma anche dimostrabile, la ricerca più recente ha abbracciato un vero e proprio cambio di paradigma. Questo nuovo orientamento si concentra sull'utilizzo strategico di modelli generativi, in particolare quelli basati su reti neurali profonde.

In questo fertile contesto di ricerca si inserisce **Meteor**, un innovativo algoritmo di steganografia a chiave simmetrica. Meteor sfrutta le potenti capacità computazionali e generative dei modelli di linguaggio di grandi dimensioni (Large Language Models - LLM), originariamente derivati da architetture come GPT-2, per creare canali di comunicazione occulti e resilienti. A differenza delle tecniche steganografiche tradizionali che modificano un contenuto esistente, Meteor interviene e guida il processo di generazione stessa del contenuto. Esso utilizza la distribuzione di probabilità intrinseca del modello generativo per "pilotare" il campionamento dei token successivi in base al messaggio segreto opportunamente cifrato. Questo approccio garantisce che lo stego-object risultante sia statisticamente coerente e indistinguibile dall'output naturale del modello, rendendo la presenza del messaggio nascosto estremamente difficile, se non impossibile, da rilevare attraverso analisi statistiche convenzionali.

L'ambizioso obiettivo della presente tesi triennale è estendere il principio fondamentale di sicurezza steganografica ideato da Meteor, originariamente applicato al dominio testuale, all'ambito delle immagini digitali ad alta risoluzione. Per conseguire questo scopo, viene sfruttata l'architettura **VQ-GAN** (Vector Quantized Generative Adversarial Network). La scelta strategica di questa specifica architettura deriva dalla

sua intrinseca capacità di modellare immagini estremamente complesse attraverso la creazione e l'utilizzo di un vocabolario discreto di "token visivi", memorizzati in un codebook. Questa rappresentazione discreta apre le porte all'applicazione di un modello Transformer autoregressivo, ampiamente utilizzato nella generazione sequenziale, per guidare il processo di sintesi dell'immagine. Il lavoro svolto mira dunque a dimostrare con rigore e sperimentazione come sia possibile incorporare messaggi cifrati direttamente durante la fase di generazione dell'immagine da parte dell'architettura VQ-GAN. L'obiettivo finale è ottenere immagini non solo visivamente simili a quelle generate dallo stesso modello, ma anche intrinsecamente robuste contro tentativi sofisticati di rilevamento steganografico.

Le implicazioni pratiche e teoriche di questo approccio sono potenzialmente rivoluzionarie per lo sviluppo di strumenti di comunicazione *copyright-resistant*. La capacità di abilitare lo scambio sicuro e nascosto di informazioni all'interno di immagini di alta qualità offre un livello inedito di protezione per la privacy degli utenti e per la libertà di espressione in contesti digitali sempre più soggetti a sorveglianza e controllo.

Il presente elaborato è stato organizzato con cura per condurre il lettore attraverso un percorso logico e approfondito, dalla teoria alla pratica:

- Il **Capitolo 2** fornisce un'analisi completa e dettagliata del background teorico indispensabile, approfondendo lo stato dell'arte delle tecniche steganografiche esistenti e i principi fondamentali di funzionamento dei modelli generativi più avanzati, con un'enfasi particolare sulle architetture GAN (Generative Adversarial Networks) e Transformer.
- Il **Capitolo 3** presenta le definizioni formali e le specifiche tecniche del sistema proposto, illustrando in dettaglio l'architettura implementata e le modifiche apportate al meccanismo di campionamento dei token visivi per consentire l'embedding del messaggio segreto cifrato direttamente nel flusso generativo. Vengono inoltre discussi i limiti teorici e pratici del lavoro svolto, evidenziando le sfide affrontate e le soluzioni adottate per superarle.
- Il **Capitolo 4** presenta l'idea alla base del lavoro di tesi, l'architettura completa del sistema implementato e i limiti teorici e pratici del lavoro svolto. Vengono illustrate in dettaglio le modifiche apportate al meccanismo di campionamento dei token visivi per consentire

l'embedding del messaggio segreto cifrato direttamente nel flusso generativo.

- Il **Capitolo 5** espone in modo esaustivo i risultati delle sperimentazioni condotte. Vengono valutate sia la qualità visiva delle immagini generate, attraverso l'utilizzo di metriche consolidate come la Fréchet Inception Distance (FID), sia la capacità steganografica del sistema, analizzando il payload trasferibile e la robustezza contro attacchi di rilevamento.
- Infine, il **Capitolo 6** trae le conclusioni finali del lavoro svolto, riassumendo i contributi principali della ricerca e delineando una serie di possibili sviluppi futuri, mirati al miglioramento incrementale dell'efficienza, della robustezza e della sicurezza complessiva del sistema proposto.

---

## STATO DELL'ARTE

---

### 2.1 METEOR: UN FRAMEWORK DI STEGANOGRAFIA GENERATIVA PER IL TESTO

La necessità di una solida comprensione teorica, indispensabile per contestualizzare appieno il presente lavoro di ricerca, si articola attraverso una costellazione di concetti interdipendenti che convergono in un'unica opera fondamentale: il lavoro di [KAP+21], comunemente noto come *Meteor*. Questa pionieristica indagine, che va oltre una mera disamina della steganografia classica e di quella generativa, introduce primariamente un approccio metodologico e, in secondo luogo, un framework robusto ed efficiente deputato alla *generazione di messaggi testuali contenenti informazioni celate*.

La peculiarità di queste informazioni risiede nella loro intrinseca invisibilità non solo all'occhio umano, ma anche, e soprattutto, alle più sofisticate tecniche di steganalisi basate su divergenza statistica. La ragione di tale elusività risiede nella formalizzazione del concetto di *perfectly secure steganography* nel dominio del linguaggio naturale: il testo generato da *Meteor* non manifesta alcuna deviazione statistica significativa rispetto a un testo prodotto autonomamente dal medesimo modello linguistico di base (il cosiddetto *cover distribution*). Come verrà dettagliato in seguito, *Meteor* si avvale di un modello linguistico che ha raggiunto una notevole notorietà, estendendosi ben oltre gli ambiti accademici tradizionali, configurandosi come uno dei primi Transformer a larga scala a influenzare il dibattito pubblico sulla capacità generativa delle IA. Nello specifico, *Meteor* impiega il modello **GPT-2** (Generative Pre-trained Transformer 2), caratterizzato da un'architettura *decoder-only* addestrata su un corpus massivo di dati testuali (WebText). Tuttavia, l'architettura del framework è stata concepita con una notevole flessibilità, risultando agnostica rispetto al modello linguistico sottostante (*Backbone LLM*). Questa modularità permette a *Meteor* di beneficiare direttamente dei progressi nello stato


dell'arte dei modelli linguistici, poiché l'efficacia della steganografia è intrinsecamente legata alla capacità del modello di approssimare la vera distribuzione del linguaggio umano ( $P_{data}$ ).

Per una comprensione ancora più profonda, è opportuno esaminare il contesto socio-tecnologico in cui *Meteor* è maturato e le problematiche specifiche che si proponeva di risolvere, segnatamente la necessità di canali di comunicazione resistenti alla censura automatizzata.

L'essenza di *Meteor* risiede nell'idea innovativa di utilizzare un modello generativo per la creazione di contenuti steganografici, sfruttando la sua capacità di modellare la probabilità condizionata  $P(x_t|x_{<t})$ . In termini pratici, il modello agisce come un sofisticato stimatore di densità: data una sequenza di contesto iniziale (*prompt*), esso fornisce una distribuzione di probabilità dettagliata (solitamente tramite una funzione *softmax* applicata ai *logits*) per tutti i possibili *token* contenuti nel vocabolario  $\mathcal{V}$ . La scelta del *token* da inserire nella sequenza viene effettuata tramite un meccanismo di campionamento che mappa bit del messaggio segreto in indici del vocabolario, seguendo l'ordinamento indotto dalla distribuzione di probabilità. Questa metodologia trasforma il processo di inferenza in un'operazione di codifica di canale: il testo risultante è statisticamente probabile secondo il modello, ma contiene un messaggio segreto decodificabile univocamente dal destinatario. La decodifica è resa possibile a condizione che il ricevente disponga dello stesso modello linguistico, della medesima sequenza di contesto e di una chiave privata condivisa (*shared secret*), necessaria per inizializzare il generatore di numeri pseudo-casuali o per definire le permutazioni degli indici del vocabolario.

Costruiamo ora uno scenario illustrativo volto a consolidare la comprensione del meccanismo operativo di *Meteor*. Immaginiamo una comunicazione confidenziale tra due entità, Alice (A) e Bob (B), che desiderano scambiarsi informazioni sensibili attraverso un canale pubblico monitorato. L'obiettivo primario è impedire a un osservatore avversario, Eve (E), di rilevare la presenza stessa della comunicazione (*steganographic undetectability*). Un contesto critico si verifica quando Alice o Bob operano all'interno di infrastrutture soggette a *Deep Packet Inspection* (DPI) o filtraggio governativo stringente. In tali scenari, i messaggi cifrati tramite crittografia standard (come AES o RSA) presentano un'entropia elevata e una distribuzione dei byte uniforme, risultando facilmente identificabili come traffico anomalo e soggetti a blocco immediato (Figura 1). Un esempio emblematico è il sistema descritto in [ENS+15], il "Great Firewall", che impiega euristiche avanzate per discriminare tra traffico legittimo e

protocolli di tunneling o cifratura. All'interno di questo quadro ostile, la steganografia generativa supera il limite della crittografia tradizionale: non si limita a proteggere il contenuto, ma nasconde l'esistenza stessa dell'atto comunicativo. Eve, osservando il transito di un testo coerente e stilisticamente appropriato, non ha basi statistiche per etichettare la comunicazione come sospetta<sup>1</sup>.



**Figura 1:** Rappresentazione schematica di una comunicazione tra Alice (A) e Bob (B) in presenza di un osservatore esterno, Eve (E), e di un sistema di filtraggio dei contenuti (Firewall) che analizza la firma statistica dei pacchetti.

Dal punto di vista teorico, la progettazione di *Meteor* ha dovuto risolvere due criticità fondamentali legate alla natura del linguaggio naturale.

La prima riguarda la definizione di un *sampler steganografico* efficiente. L'algoritmo deve mappare stringhe di bit in token in modo che la selezione rispetti fedelmente la distribuzione  $P(x_t|x_{<t})$ . *Meteor* implementa algoritmi di campionamento come l'*Arithmetic Coding* steganografico o il *Huffman Coding* adattivo, che permettono di mantenere l'efficienza di codifica vicina all'entropia del modello, garantendo al contempo che ogni token scelto sia "giustificato" dalla probabilità assegnata dal Transformer.

<sup>1</sup> Nel presente scenario, "segreto" e "privato" sono usati in senso tecnico: una comunicazione è steganograficamente sicura se la divergenza di Kullback-Leibler tra la distribuzione dei messaggi naturali e quella dei messaggi steganografici tende a zero.

La seconda sfida è legata alla dinamicità dell'entropia testuale. In porzioni di testo ad alta densità semantica o vincoli sintattici rigidi (bassa entropia), la libertà di scelta del token successivo è quasi nulla. Ad esempio, data la sequenza "*The largest carnivore of the Cretaceous period was the Tyrannosaurus*", il token "Rex" ha una probabilità prossima a 1.0. Tentare di codificare bit in questa posizione forzando un token alternativo (es. "Bison") produrrebbe un'anomalia semantica macroscopica, facilmente rilevabile da un classificatore neurale. *Meteor* introduce quindi una soglia di entropia minima: il sistema analizza la distribuzione di probabilità ad ogni passo temporale e decide dinamicamente se la varianza è sufficiente per ospitare informazione. Se l'entropia è inferiore a un valore critico  $\tau$ , il sistema genera il token più probabile senza inserire bit segreti. Questa strategia di codifica adattiva (*adaptive rate*) assicura che il throughput informativo sia massimizzato solo dove il linguaggio offre naturale ridondanza, preservando l'integrità statistica del segnale steganografico.

## 2.2 VQ-GAN: UN'ARCHITETTURA GENERATIVA A BASE TRANSFORMER PER IMMAGINI AD ALTA RISOLUZIONE

Successivamente, analizzeremo le ragioni per cui architetture alternative, come le VQ-GAN (Vector Quantized Generative Adversarial Networks), sono state considerate per l'estensione di tali concetti al dominio visuale.



---

## BIBLIOGRAFIA

---

- [EUR] European Pirate Party. *Chat control 2.0: the sequel nobody asked for*. URL: <https://europeanpirates.eu/chatcontrol-the-sequel-nobody-asked-for/>.
- [KAP+] Gabriel Kaptchuk et al. *Meteor. Cryptographically secure steganography for realistic distributions*. URL: <https://meteorfrom.space/> (visitato il giorno 10/07/2025).
- [SHA] Adrian Shahbaz. *The rise of digital authoritarianism*. URL: <https://freedomhouse.org/report/freedom-net/2018/rise-digital-authoritarianism>.
- [SUA26] Matteo Suanno. «Cosa significa che Starlink non è più accessibile all'esercito russo in Ucraina». In: (6 feb. 2026). URL: <https://www.wired.it/article/cosa-sappiamo-blocco-starlink-militari-ucraina/>.
- [BS25] Dave Bergmann e Cole Stryker. *Diffusion models*. 17 Apr. 2025. URL: <https://www.ibm.com/think/topics/diffusion-models> (visitato il giorno 10/07/2025).
- [SAB25] Wisdom Sablah. *WhatsApp Banned Countries List & How to Bypass the Ban* 2026. 13 Nov. 2025. URL: <https://www.cloudwards.net/countries-where-whatsapp-is-banned/>.
- [XU+25] Yuhua Xu et al. «Approximate Gaussian Mapping for Generative Image Steganography». In: *arXiv preprint arXiv:2510.07219* (2025).
- [APA+24] Richard Apau et al. «Image steganography techniques for resisting statistical steganalysis attacks: A systematic literature review». In: *PLOS ONE* 19.9 (set. 2024), pp. 1–47. DOI: [10.1371/journal.pone.0308807](https://doi.org/10.1371/journal.pone.0308807). URL: <https://doi.org/10.1371/journal.pone.0308807>.
- [LI+24] Li Li et al. «Image Steganography and Style Transformation Based on Generative Adversarial Network». In: *Mathematics* 12.4 (2024). ISSN: 2227-7390. DOI: [10.3390/math12040615](https://doi.org/10.3390/math12040615). URL: <https://www.mdpi.com/2227-7390/12/4/615>.

- [SCA24] Simone Scardapane. *Alice's Adventures in a Differentiable Wonderland – Volume I, A Tour of the Land*. 26 Apr. 2024. URL: <https://arxiv.org/abs/2404.17625>.
- [BER23] Giulia Bertazzini. «An overview of Diffusion Models in Multimedia Forensics: Generating and Detecting Synthetic Images». 27 Ott. 2023.
- [ERD23] Kemal Erdem. *Step by step visual introduction to diffusion models*. Nov. 2023. URL: <https://erdem.pl/2023/11/step-by-step-visual-introduction-to-diffusion-models> (visitato il giorno 10/07/2025).
- [BOU22] Daniel Bourke. *Learn PyTorch for deep learning in a day. Literally*. 24 Lug. 2022. URL: [https://www.youtube.com/watch?v=Z\\_ikDlimN6A](https://www.youtube.com/watch?v=Z_ikDlimN6A).
- [GU+21] Shuyang Gu et al. «Vector Quantized Diffusion Model for Text-to-Image Synthesis». In: *CoRR* abs/2111.14822 (2021). arXiv: [2111.14822](https://arxiv.org/abs/2111.14822). URL: <https://arxiv.org/abs/2111.14822>.
- [KAP+21] Gabriel Kaptchuk et al. *Meteor: Cryptographically Secure Steganography for Realistic Distributions*. Cryptology ePrint Archive, Paper 2021/686. 2021. URL: <https://eprint.iacr.org/2021/686> (cit. a p. 11).
- [SUB+21] Nandhini Subramanian et al. «Image Steganography: A Review of the Recent Advances». In: *IEEE Access* 9 (2021), pp. 23409–23423. DOI: [10.1109/ACCESS.2021.3053998](https://doi.org/10.1109/ACCESS.2021.3053998).
- [WEN21] Lilian Weng. *What are Diffusion Models?* 11 Lug. 2021. URL: <https://lilianweng.github.io/posts/2021-07-11-diffusion-models/>.
- [ERO20] Patrick Esser, Robin Rombach e Björn Ommer. «Taming Transformers for High-Resolution Image Synthesis». In: *CoRR* abs/2012.09841 (2020). arXiv: [2012.09841](https://arxiv.org/abs/2012.09841). URL: <https://arxiv.org/abs/2012.09841>.
- [LIU+20] Jia Liu et al. «Recent Advances of Image Steganography With Generative Adversarial Networks». In: *IEEE Access* 8 (2020), pp. 60575–60597. DOI: [10.1109/ACCESS.2020.2983175](https://doi.org/10.1109/ACCESS.2020.2983175).
- [ZHA+19] Zhuo Zhang et al. «Generative Steganography by Sampling». In: *IEEE Access* 7 (2019), pp. 118586–118597. DOI: [10.1109/ACCESS.2019.2920313](https://doi.org/10.1109/ACCESS.2019.2920313).

- [HU+18] Donghui Hu et al. «A Novel Image Steganography Method via Deep Convolutional Generative Adversarial Networks». In: *IEEE Access* 6 (2018), pp. 38303–38314. doi: [10.1109/ACCESS.2018.2852771](https://doi.org/10.1109/ACCESS.2018.2852771).
- [CON16] Kate Conger. *WhatsApp blocked in Brazil again*. 19 Lug. 2016. URL: <https://techcrunch.com/2016/07/19/whatsapp-blocked-in-brazil-again/>.
- [ENS+15] Roya Ensafi et al. «Examining How the Great Firewall Discovers Hidden Circumvention Servers». In: *Proceedings of the 2015 Internet Measurement Conference*. IMC '15. Tokyo, Japan: Association for Computing Machinery, 2015, pp. 445–458. ISBN: 9781450338486. doi: [10.1145/2815675.2815690](https://doi.org/10.1145/2815675.2815690). URL: <https://doi.org/10.1145/2815675.2815690> (cit. a p. 12).